

PAttn과 LightTS를 결합해 전류 신호를 이용한 모터 이상 탐지 딥러닝 기반 모델

김해영*, 구본근**, 반재필***, 구교권****

Deep learning - based motor anomaly detection model using current signals with combined PAttn and LightTS modules

Haeyoung Kim*, Bon-geun Koo**, Japil Ban***, and Gyogwon Koo****

요 약

모터 이상 탐지는 산업안전과 밀접하게 연관 되어 있어 매우 중요하다. 본 연구에서는 모터의 고장을 효과적으로 감지하기 위한 딥러닝 기반 이상 탐지 모델을 제안하였다. 모델은 전역적 의존성을 학습하는 attention 기반 PAttn 모듈과 지역적 및 장기적 패턴의 상호작용을 학습하는 LightTS 모듈을 결합하여 구성하였다. 또한 두 모듈의 출력을 각각 최적화하기 위해 가중 합 기반 평균 제곱 오차 손실 함수를 적용하여, 두 모듈의 손실을 동시에 최소화하고 균형적으로 학습될 수 있도록 설계하였다. 제안된 모델은 area under the receiver operating characteristic curve (AUC) 0.8873의 성능을 보여 비교 모델들보다 우수한 결과를 보여준다. 이러한 결과를 통해 제안된 모델의 구조가 전류 신호 기반 모터 이상 탐지에서 시계열 패턴을 효과적으로 학습하고, 모델의 안정성을 향상시킴을 확인하였다.

Abstract

Motor anomaly detection is critically important as it is closely related to industrial safety. In this study, a deep learning - based anomaly detection model is proposed for effective motor fault diagnosis. The model combines two complementary modules: the attention-based PAttn module, which captures global dependencies, and the LightTS module, which learns local and long-term pattern interactions. To achieve balanced optimization, a weighted mean square error loss function is applied to both module outputs, enabling simultaneous minimization of each module's loss. The proposed model achieved an area under the receiver operating characteristic curve (AUC) of 0.8873, outperforming other comparative models. These results confirm that the proposed model effectively learns multi-scale temporal patterns from current signals and improves model stability for motor anomaly detection.

Key words

Anomaly detection, attention-based method, deep learning, motor, focus measure

* 국립금공과대학교 전자공학과 석사과정, sunh@kumoh.ac.kr

** 대구경북과학기술원 기초학부 학사과정, nice2045@dgist.ac.kr

*** 국립금공과대학교 항공기계전자융합전공 교수, banjp@kumoh.ac.kr

**** 대구경북과학기술원 지능형로봇연구부 선임연구원, gkoo@dgist.ac.kr(교신저자)

※ 본 연구는 과학기술정보통신부에서 지원하는 DGIST 기관고유사업에 의해 수행되었으며(25-IT-02), 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임(RS-2025-23525404).

I. 서 론

모터는 운송, 해양 항공우주 등 다양한 산업 분야에서 광범위하게 사용된다. 그러나 열악한 작업 환경이나 부적절한 조작으로 인해 모터의 고장이 자주 발생한다. 갑작스러운 고장은 높은 유지보수 비용을 초래한다. 특히, 항공기, 기차, 자동차, 발전소 및 화학 공장과 같은 안전과 밀접하게 관련된 분야에서는 치명적이다. 따라서 기계에 대한 결함 진단을 수행하는 것은 매우 중요하다 [1, 2].

모터 결함 진단 방법은 크게 고장 후 유지보수(breakdown maintenance), 예방 유지보수(preventive maintenance), 예지 유지보수(predictive maintenance)가 존재한다. 고장 후 유지보수는 장비가 실제로 고장 난 후에야 수리 및 교체 조치를 취하는 방식으로, 단기적으로는 단순하고 비용 효율적이었으나, 결과적으로는 심각한 생산 손실, 안전 위험, 그리고 높은 수리 비용을 초래한다. 예방 유지보수는 정해진 일정에 따라 정기 점검 및 유지보수를 수행하는 방식으로, 알려진 마모나 손상 문제를 미리 해결하여 예기치 못한 고장을 방지하는 것을 목표로 했다. 예방 유지보수는 일정 부분 계획되지 않은 가동 중단을 줄였으나, 항상 효율적인 것은 아니었고, 종종 불필요한 유지보수 작업 및 관련 비용을 발생시켰다.

최근에 인공지능 기술이 산업 분야와 많이 접합되면서 예지 유지보수가 주목받고 있다 [3]. 이는 센서, 모니터링 시스템, 예측 알고리즘을 통해 실시간 데이터를 분석하여 장비 상태를 평가하고, 잠재적인 결함을 식별하며, 이에 따라 유지보수 일정을 최적화한다. 이를 통해 조직은 유지보수 계획을 최적화하고, 비용을 절감하며, 장비 가동 시간을 극대화하고, 전반적인 운영 효율성을 향상시킬 수 있다.

예지 유지보수의 예측 알고리즘으로 딥러닝 모델들이 많이 제안되었다 [4, 5]. 이전 알고리즘들은 모두 진동 데이터를 사용해 학습했다. 하지만 진동 신호를 측정할 때는 가속도 진동 센서를 모두 부착해야만 측정할 수 있다는 한계가 있다.

본 논문에서는 이러한 한계점을 해결하기 위해 추가적인 센서 부착 없이 측정할 수 있어 경제적인




그림 1. 전반적인 모델 구조
Fig. 1. Overall model structure

전류 데이터를 사용한 모터의 이상을 탐지하는 딥러닝 모델을 제안한다 [5]. 논문에서 제안하는 딥러닝 모델은 PAttn [6], LightTS [7]을 활용하였다. PAttn은 패치 임베딩과 attention 기법을 사용해 시계열 데이터를 처리하는 모델로 LLM과 비교해 매우 가볍지만 좋은 성능을 보인다. LightTS는 연속, 간격 샘플링과 MLP (Multi layer perceptron) 구조만을 사용한다. 이 모델은 사용해 비교적 간단한 모델로도 연속 샘플링에 의해 짧은 기간의 지역적 패턴을 포착하고 간격 샘플링에 의해 장기적인 패턴을 포착해 특징들의 상호작용을 학습한다. 이러한 장점이 있는 모델들을 결합해 전류 데이터의 이상을 탐지하는 모델을 제안한다. 또한, 각 모델의 최적화를 위해 모델별 출력에 대한 손실을 모두 계산해 최적화한다.

II. 제안하는 딥러닝 모델

제안하는 모델은 PAttn 모듈과 LightTS 모듈을 사용해 구성되었다. 모델의 전반적인 구조는 그림 1과 같다. 제안된 모델은 PAttn 모듈이 1차로 사용되어 패치 단위의 전역 의존성을 학습하고, 2차로 LightTS 모듈이 지역적, 장기적 패턴을 학습하는 구조를 사용한다. 또, 모듈들이 상호 보완적으로 학습되며 안정성을 높이기 위해 PAttn 모듈의 1차 출력과 LightTS 모듈의 2차 출력을 input과 대조하여 손실을 계산한다. 여기서, 손실 함수는 평균 제곱 오차 (Mean square error)를 가중 합해서 학습한다.

2.1 PAttn 모듈 & LightTS 모듈

첫 번째인 PAttn 모듈은 입력 시계열 데이터를 패치 단위로 변환한 후, 각 패치 간의 상관관계를 학습하기 위해 Self-attention 기반 인코더 구조를 사용하였다. 입력 데이터는 먼저 ReplicationPad1d

layer를 통해 패딩 되어 고정된 길이의 입력으로 맞춰지고, 이후 Linear layer를 통해 임베딩 차원으로 확장된다. 인코더는 하나의 Layer로 구성되며, 이 내부에는 Full attention 메커니즘이 적용되어 패치 간 의존성을 포착한다. 각 attention layer 이후에는 Conv1d layer로 구성된 피드 포워드 경로를 통해 지역적 특징을 보강하고, Layer 정규화와 Dropout을 적용하여 학습 안정성을 확보하였다. 인코더의 출력을 통합한 후, 최종적으로 Linear layer를 통해 고차원 특징 벡터를 생성한다.

두 번째인 LightTS 모듈은 입력 특징의 공간적 관계를 정교하게 조정하기 위한 Information Exchange Block (IEBlock) 기반 다중 단계 특징 추출기로 설계되었다. 각 IEBlock은 Spatial projection, Channel projection, Output projection 세 부분으로 구성된다. spatial projection은 입력 공간 차원을 축소 및 비선형 변환을 통해 지역 정보를 강화하고, Channel projection은 채널 간 상호작용을 학습하며, Output projection은 통합된 특징을 다음 블록으로 전달하기 위한 변환을 수행한다. LightTS 모듈은 총 세 개의 IEBlock으로 구성되어 있으며, 각 블록의 출력은 Chunk projection 계층을 통해 차원 축소 후 병합된다. 마지막으로 Linear layer를 통해 시계열적 예측 또는 분류에 적합한 형태로 특징을 정렬한다.

이와 같은 구조를 통해 제안 모델은 패치 단위 전역 의존성 학습과 지역적, 장기적 패턴 상호작용 학습을 동시에 수행함으로써, 입력 데이터의 다중 스케일 및 다중 관점 특징을 효과적으로 통합하도록 설계되었다.

2.2 가중 합 손실 함수

본 논문에서는 제안된 모델의 두 개 모듈이 각각 독립적이고 안정적으로 학습될 수 있도록 평균 제곱 오차(Mean Square Error, MSE)를 각 모듈의 출력에 개별적으로 적용하였다. MSE는 예측값과 실제값 간의 오차 제곱 평균으로, 예측의 정확도를 정량적으로 평가하는 데 널리 사용되는 회귀 기반 손실 함수이다.

일반적인 MSE는 다음과 같이 정의된다.

$$L = \frac{1}{N} \left(\sum_{i=1}^N (I_i - O_i)^2 \right) \quad (1)$$

여기서 I_i 는 i 번째 입력, O_i 는 모듈의 i 번째 예측값을 의미하며, N 은 데이터 개수를 나타낸다. 제안하는 손실 함수는 두 모듈의 손실을 가중 합 형태로 결합하여 다음과 같이 정의하였다.

$$\begin{aligned} L_{total} &= \alpha L_1 + \beta L_2 \\ &= \frac{1}{N} \sum_{i=1}^N (\alpha (I_i - O_{i,1})^2 + \beta (I_i - O_{i,2})^2) \end{aligned} \quad (3)$$

여기서 α 와 β 는 각 모듈의 학습 중요도를 조절하기 위한 가중치 계수이다. 이와 같은 설계는 두 모듈이 상호 보완적으로 학습되도록 하며, 하나의 모듈이 과도하게 주도하는 현상을 방지하여 모델의 안정적 수렴과 예측 성능 향상에 기여한다. 또, 이렇게 두 모듈 손실을 동시에 최소화함으로써, attention 기반 표현과 지역적 특징 추출 표현을 균형 있게 최적화할 수 있다. 최종적으로 이상 탐지는 final output 만을 가지고 탐지한다.

III. 실험

3.1 데이터 및 고정 파라미터

제안된 모델은 [8]에서 제공된 모터 전류 데이터셋을 사용했다. 실험에 사용된 모터는 정격 속도의 50, 75, 100% 조건에서 운전되었으며, 고장 유형으로는 고정자 권선 단락을 선택하여 학습했다.

데이터 전처리 과정에서는 window sliding 기법을 적용했고, window length는 800, stride는 1로 설정했다. 학습 및 검증 단계에서는 정상 데이터만을 사용해 학습했고, 평가 단계에서는 정상과 이상 데이터를 모두 사용해 학습했다. 학습, 검증, 평가 셋은 각각 7200, 6470, 8325개의 샘플로 구성되어 있다. 평가 셋은 정상과 이상 샘플이 각각 6450, 1875로 구성되어 있다. 모든 정상 데이터에는 세 가지 정격속도(50, 75, 100)가 포함되어 있다. 데이터 정규화에는 최대-최소 스케일러를 사용하여 모든 입력 값을 0-1 범위로 변환하였다. 또, 모든 실험 결과는 Area under the receiver operating characteristic curve (AUC)로 나타냈다.

모델 학습은 batch size 32, 최대 epoch 300, α

표 1. Initial learning rate 최적화 실험 결과 (AUC 비교)
Table 1. Comparison of AUC results for initial learning rate tuning experiments

Learning rate	AUC
1×10^{-3}	0.8805
1×10^{-4}	0.8873
1×10^{-5}	0.8820

=1, $\beta=1$ 의 설정에서 수행되었다. 또, 모델의 성능을 높이기 위해 pytorch에서 제공하는 CosineAnnealing scheduler, Adam optimizer를 사용했다.

3.2 하이퍼 파라미터 실험

learning rate는 과도하게 높게 설정할 경우 overshooting 현상이 발생할 수 있고, 너무 낮게 설정할 경우 local minimum에 빠질 위험이 있다. 그렇기에 적절한 learning rate를 찾는 것은 매우 중요한 일이다. 제안된 모델의 적절한 learning rate를 찾기 위해 initial learning rate에 대한 실험을 진행했고, 결과는 표 1에 나타났다. initial learning rate를 1×10^{-4} 으로 설정했을 때가 가장 좋은 결과임을 보인다. 그래서 다음 실험은 1×10^{-4} 으로 진행하였다.

3.3 결과 비교 실험

제안된 모델의 성능을 입증하기 위해 표 2에 다른 모델들과 비교한 결과를 나타냈다. 비교 모델들과 비교해 제안된 모델이 가장 좋은 결과를 보여준다. 따라서 제안된 모델은 PAttn과 LightTS를 결합하고 가중 합 손실 함수를 적용하여 좋은 성능을 보여주는 모터 이상 탐지 모델임을 증명했다.

IV. 결 론

본 논문에서는 모터의 고장을 효과적으로 감지하기 위한 이상 탐지 딥러닝 모델을 제안했다. 제안된 모델은 전역적 의존성을 학습하는 PAttn과 지역적 및 장기적 패턴의 상호작용을 학습하는 LightTS 모듈의 장점을 잘 결합했다. 또한 두 모듈에 가중 합 기반 손실 함수를 적용함으로써, 각 모듈의 손

표 2. 비교 모델들과 AUC 결과 비교

Table 2. Comparison of AUC results with different models

Comparison model	AUC
Transformer [9]	0.5505
Autoformer [10]	0.5797
FEDformer [11]	0.6368
FiLM [12]	0.7551
LightTS [7]	0.8170
Pyraformer [13]	0.7880
Timesnet [14]	0.6504
Crossformer [15]	0.5974
PatchTST [16]	0.7916
Itransformer [17]	0.7585
PAttn [6]	0.8318
Proposed model	0.8873

실을 동시에 최소화하고, 균형 있게 최적화할 수 있도록 설계하였다. 이를 통해 모델의 학습 안정성이 향상되었으며, 제안된 구조가 효과적으로 동작함을 실험적으로 입증하였다. 제안된 모델이 기존 모델 대비 우수한 성능 area under the receiver operating characteristic curve (AUC) 0.8873을 달성함으로써 좋은 성능임을 입증했다. 향후 연구에서는 본 모델을 실시간 모터 상태 모니터링 시스템에 적용하여 실시간 이상 감지 및 예측 유지 보수로 확장하는 연구를 목표로 한다.

참 고 문 헌

- [1] B. Liu, C. H. Chen, P. Zheng, and G. Zhang, "An adaptive parallel feature learning and hybrid feature fusion-based deep learning approach for machining condition monitoring," IEEE Transactions on Cybernetics, vol. 53, no. 12, pp. 7584-7595, Dec. 2023.
- [2] Y. He and W. Shen, "A federated cross-machine diagnostic framework for machine-level motors with extreme label shortage," Advanced Engineering Informatics, vol. 61, Article 102511, 2024.
- [3] V. H. Wentz, J. N. Maciel, J. J. G. Ledesma, and O. H. Ando Junior, "Solar irradiance forecasting to short-term PV power: Accuracy comparison of

- ANN and LSTM models,” *Energies*, vol. 15, no. 7, p. 2457, 2022.
- [4] Z. Wang, P. Liang, R. Bai, Y. Liu, J. Zhao, L. Yao, J. Zhang, and F. Chu, “Few-shot fault diagnosis for machinery using multi-scale perception multi-level feature fusion image quadrant entropy,” *Advanced Engineering Informatics*, vol. 63, p. 102972, 2025.
- [5] Z. Liu, L. Kong, J. Yu, D. Tang, L. Tian, and N. Su, “An advanced fault diagnosis model for complex electromechanical systems with enhanced feature extraction,” in *Proc. 2025 IEEE 20th Conf. Industrial Electronics and Applications (ICIEA)*, pp. 1–6, 2025.
- [6] J. -H. Han and S. -U. Park, S. -K. Hong, “A Study of Vibration and Current Data Characteristic Analysis for Motor Mechanical Fault Level Determination by Deep Learning”, *The Transactions of the Korean Institute of Electrical Engineers*, vol. 70, pp. 1509-1516
- [7] T. C. Krause, Ł. Huchel, D. H. Green, K. Lee, and S. B. Leeb, “Nonintrusive motor current signature analysis,” *IEEE Transactions on Instrumentation and Measurement*, vol. 72, pp. 1–13, 2023.
- [8] R. D. Geertsma, “Motor current and vibration monitoring dataset for various faults in an E-motor-driven centrifugal pump,” *Data in Brief*, vol. 52, p. 109987, 2024.
- [9] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.
- [10] H. Wu, J. Xu, J. Wang, and M. Long, “Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, pp. 22419–22430, 2021.
- [11] T. Zhou, Z. Ma, Q. Wen, X. Wang, L. Sun, and R. Jin, “FedFormer: Frequency enhanced decomposed transformer for long-term series forecasting,” in *Proc. Int. Conf. Machine Learning (ICML)*, pp. 27268–27286, 2022.
- [12] T. Zhou, Z. Ma, Q. Wen, L. Sun, T. Yao, W. Yin, R. Jin et al., “FiLM: Frequency improved Legendre memory model for long-term time series forecasting,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, pp. 12677–12690, 2022.
- [13] S. Liu, H. Yu, C. Liao, J. Li, W. Lin, A. X. Liu, and S. Dustdar, “Pyraformer: Low-complexity pyramidal attention for long-range time series modeling and forecasting,” in *Proc. AAAI Conf. Artificial Intelligence (AAAI)*, 2022.
- [14] H. Wu, T. Hu, Y. Liu, H. Zhou, J. Wang, and M. Long, “TimesNet: Temporal 2D-variation modeling for general time series analysis,” *arXiv preprint arXiv:2210.02186*, 2022.
- [15] Y. Zhang and J. Yan, “Crossformer: Transformer utilizing cross-dimension dependency for multivariate time series forecasting,” in *Proc. 11th Int. Conf. Learning Representations (ICLR)*, 2023.
- [16] Y. Nie, “A time series is worth 64 words: Long-term forecasting with transformers,” *arXiv preprint arXiv:2211.14730*, 2022.
- [17] Y. Liu, T. Hu, H. Zhang, H. Wu, S. Wang, L. Ma, and M. Long, “iTransformer: Inverted transformers are effective for time series forecasting,” *arXiv preprint arXiv:2310.06625*, 2023.