자율주행 전기차 모터-감속기 이상 징후 탐지 경량화

2026-2 1차 발표 7조 C321027 박세진 C321028 박솔



1. 1학기 요약

Semester 1 Review

1-1 연구 배경과 목표

1-2 데이터와 고장 유형

1-3 데이터 경량화: 이미지를 시계열로

1-4 분류 방법: MiniRocket과 로지스틱 회귀

1-5 1학기 결론과 남은 숙제

1-1. 연구 배경과 목표

전기차 시장의 성장

글로벌 전기차 보급률이 빠르게 증가하며, 차량 안전성과 신뢰성에 대한 요구가 높아지고 있다.

자율주행 기술의 고도화

자율주행 시스템은 모터·배터리의 정밀한 상태 모니터링 없이는 안전한 운행을 보장할 수 없다.

실시간 예지 보전의 필요성

미세 결함을 사전에 감지하는 예지 보전 기술은 사고 예방과 유지보수 비용 절감에 직결된다.

활발한 AI기반 전기차 이상 탐지 기술 연구

TS 한국교통안전공단

한국교통안전공단은 운전자에 맞춤형 배터리 성능 정보를 제공하고, 전기차 안전성 확보와 자원순환에도 기여하는 **AI 기반 전기차 배터리 관리체계** 마련을 본격 추진한다고 14일 밝혔다.

한국교통안전공단, 「TS, AI 기술로 전기차 배터리 관리 효율성 높인다」, 2025. 08. 12.

1-2. 데이터와 고장 유형

모터감속기 550,800건

센서 종류

- Current_U — 모터 전류(U상)
- Vib_Motor — 모터 진동
- Vib_TM — 감속기 진동

차량 종류

- IONIQ
- KONA
- NIRO

결함 유형

- DEMAG — 감자_결함
- ECC10 — 편심_주의
- ECC20 — 편심_결함
- NORMAL — 정상
- RECUC — 감속기_기어_결함

코드	상태
NORMAL	정상
DEMAG	**영구자석 감자 — 모터 자석의 자력이 약해진 상태**
ECC10	편심 10% — 회전축이 중심에서 벗어난 상태
ECC20	편심 20% — 같은 결함이 더 심한 상태
REDUC	감속기 기어 결함

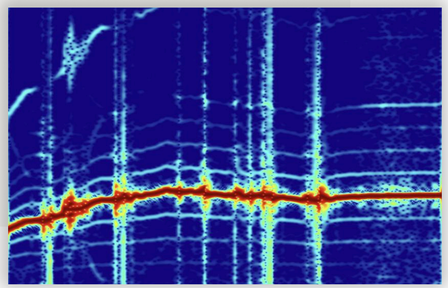
> DEMAG는 신호가 정상과 가장 비슷해 구분이 가장 어렵다

1-3. 데이터 경량화: 이미지를 시계열로

이미지를 통째로 쓰지 않고 시점마다 **특징 4개**만 뽑아 가벼운 시계열로 바꿨다

원본: 스펙트로그램 PNG

- 10초 조각마다 이미지가 1장이다
- 한 장이 2000 × 1280 픽셀이다
- 진단과 무관한 영역도 들어 있다



특징 추출 →

변환 후: 4피처 시계열

- 같은 측정의 조각을 이어 긴 신호로 복원했다
- 시점마다 **특징 4개**만 저장했다
- 시계열 모델을 바로 쓸 수 있다

특징	뜻
peak_freq_bin	**그 시점에서 에너지가 가장 큰 주파수 위치**
band_start · band_end	에너지가 있는 주파수 대역의 시작과 끝
rms	그 시점의 신호 에너지 크기(제곱평균제곱근)

1-4. 분류 방법: MiniRocket과 로지스틱 회귀

MiniRocket으로 시계열을 숫자 벡터로 바꾸고, 로지스틱 회귀로 5가지 상태 중 하나를 고른다

4피처 시계열 → 2,000행 청크 → **MiniRocket 변환** → 특징 벡터 → 로지스틱 회귀 → 5가지 상태 판정

- **청크** — 시계열을 2,000행씩 잘라 학습 샘플 1개로 썼다. 청크 1개는 원본 PNG 1장(10초) 분량이다
- **MiniRocket** — 합성곱 커널을 이용하여 시계열을 벡터로 바꿔주는 변환기
  - 커널을 학습하지 않아 딥러닝보다 훨씬 가볍고 빠르다
- **로지스틱 회귀** — 그 벡터를 받아 5가지 상태 중 하나로 판정하는 단순한 선형 분류기이다
- **누수 방지** — 같은 신호에서 잘린 청크는 train과 test 중 한쪽에만 넣었다
  - 섞이면 이미 본 신호를 다시 맞히는 셈이라 성능이 부풀려진다

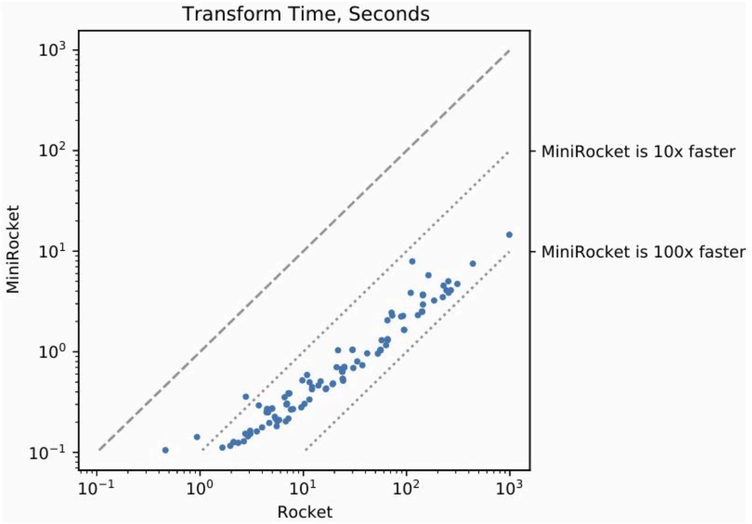


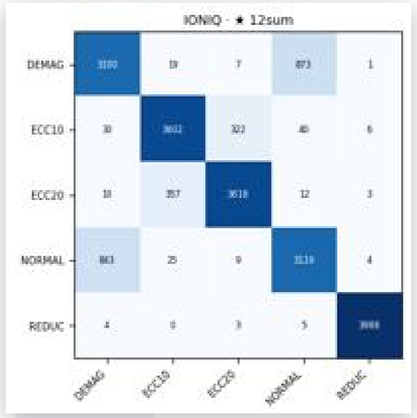
Figure 2: Transform time for MiniRocket versus Rocket for the same 109 datasets from the UCR archive.

1-5. 1학기 결론과 남은 숙제

실시간 경량화 목표는 1학기에 이미 달성했고, 남은 핵심 과제는 **DEMAG↔NORMAL 혼동**이었다

1학기 성과

- **추론 속도** — 청크 1개 판정에 16.5ms로, 목표 100ms의 약 6분의 1이었다
- **모델 크기** — 차종별 12채널 융합 모델 3개 합계 2.16MB였다
- **혼동행렬** — ECC10·ECC20·REDUC는 거의 다 맞혔다
  - IONIQ의 DEMAG→NORMAL 오분류는 약 1,800건에서 873건으로 줄었다

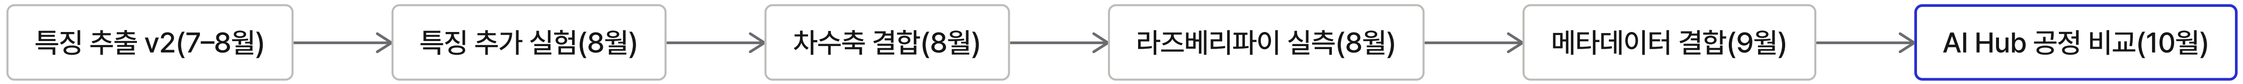


남은 숙제

01 **DEMAG↔NORMAL 혼동** — 융합 후에도 가장 큰 오류로 남았다

02 **메타데이터 미활용** — 토크·회전수·온도 정보를 아직 쓰지 않았다

03 **하드웨어 환경 실측 검증** — 엣지 환경에서의 구동 가능성 확인



2. 모델 성능 개선

Model Improvement

2-1 특징 추가 실험: 무엇을 바꿨나

2-2 확장 특징 12개의 의미

2-3 절대축과 차수축

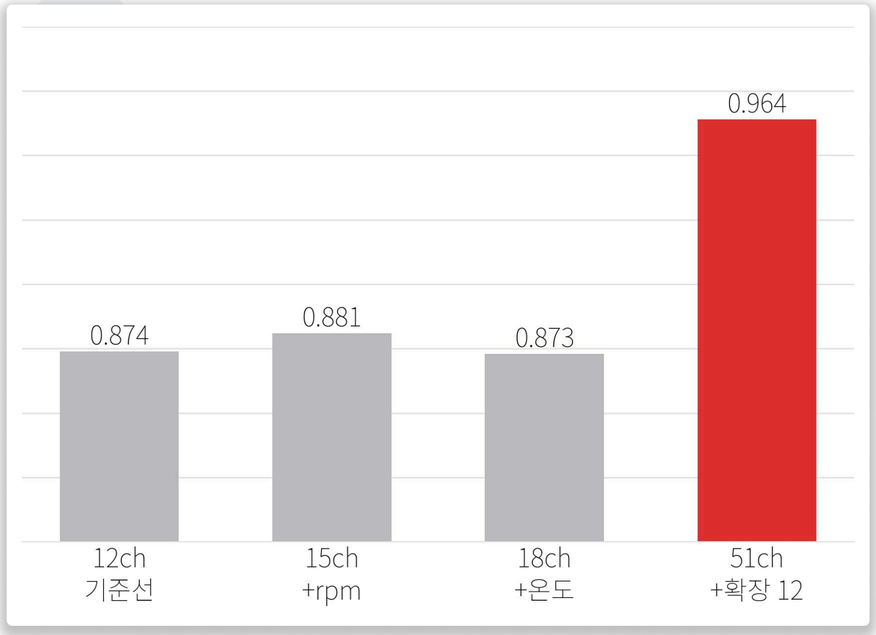
2-4 차수축 결합 결과

2-5 라즈베리파이 4 실측 결과

2-1. 특징 추가 실험: 무엇을 바꿨나

다른 조건은 고정하고 입력 특징만 하나씩 바꿨으며, **확장 특징 12개**를 넣었을 때 크게 올랐다

단계	바꾼 것	채널 구성	채널	macro-F1	판정
기준선	3센서 × 기본 4피처	기본 4×3	12	0.874	—
A1	센서마다 rpm(모터 회전수) 추가	기본 4×3 + rpm 1×3	15	0.881	채택
A2 기각됨	A1에 온도 추가	기본 4×3 + rpm 1×3 + 온도 1×3	18	0.873	기각
A3	**A1에 확장 특징 12개 추가**	기본 4×3 + rpm 1×3 + 확장 특징 12×3	51	**0.964**	**채택**



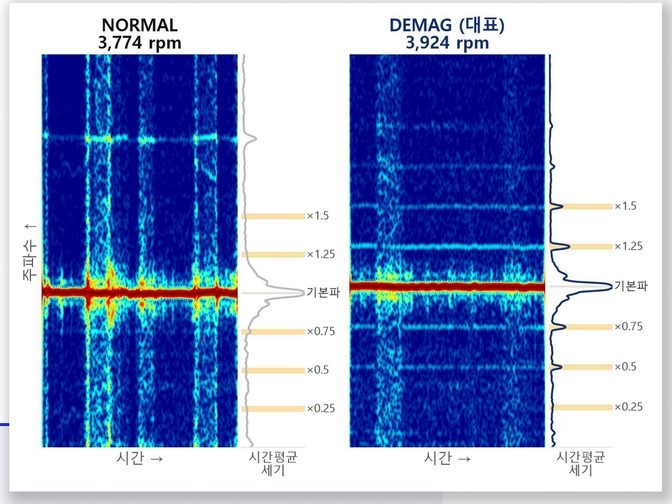
macro-F1 차종 평균 (주행 단위 교차검증)

- **채널 수** — 3센서 × 센서당 특징 수이다. 예) A3는 3 × (4 + 1 + 12) = 51 이다
- **검증 기준** — 3-fold 교차검증
- **DEMAG 재현율** — 실제 DEMAG 중 모델이 DEMAG로 맞힌 비율로, A3에서 차종별 12.4–15.8% 올랐다

2-2. 확장 특징 12개의 의미

DEMAG는 에너지가 다른 주파수 대역으로 옮겨간 특징이 있어, 에너지 분포를 직접 나타내는 특징을 추가했다

- **추가 이유** — 기본 4피처는 에너지가 "어디에 얼마나" 있는지만 담아, 대역 사이의 에너지 재분배를 표현하지 못했다
- **계산 단위** — 스펙트로그램의 각 시점(세로 한 줄)마다 아래 12개 값을 계산했다



특징	개수	계산 방법	나타내는 것
band_ratio_0–7	**8**	**주파수 축을 8구간으로 나눠 구간별 에너지 ÷ 전체 에너지**	**에너지가 어느 대역에 얼마나 몰렸는지**
centroid	1	에너지로 가중한 평균 주파수 위치	스펙트럼의 무게중심
entropy	1	에너지 분포의 엔트로피	에너지가 고르게 퍼졌는지, 몇 곳에 몰렸는지
rolloff	1	누적 에너지가 85%에 도달하는 주파수 위치	에너지 대부분이 어디까지 분포하는지
log_flatness	1	기하평균 ÷ 산술평균의 로그	잡음처럼 평평한지, 뾰족한 피크가 있는지

대역 비율 8개는 합이 1이라, 한 대역의 에너지가 다른 대역으로 옮겨 가면 값이 직접 변한다

회전 한 바퀴당 진동이 몇 번 반복되는지 보기 위해, **주파수를 회전수로 나눈 축(차수축)을 추가로 만들었다**

절대축 (Hz)

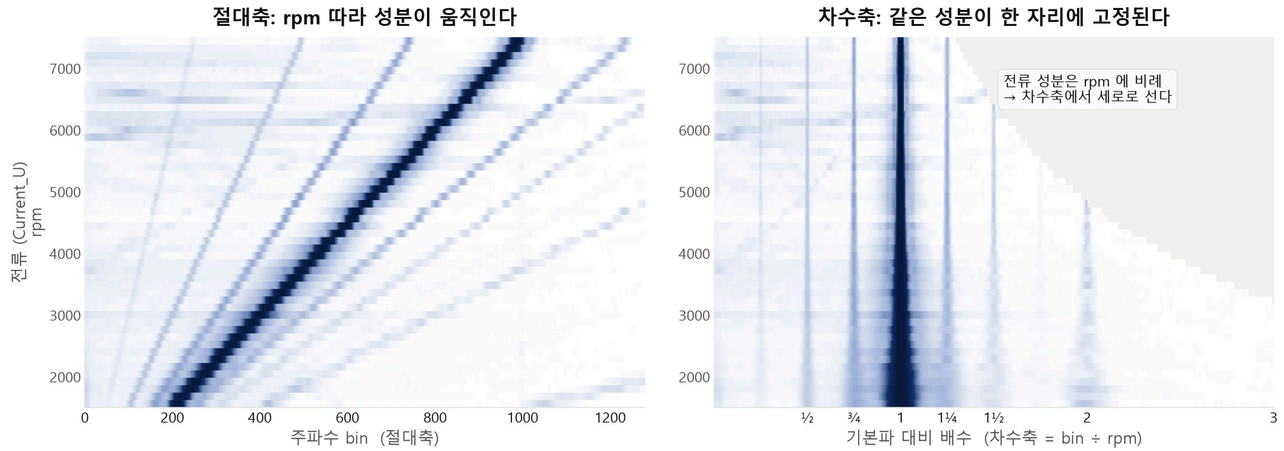
- 주파수를 그대로 쓴다
- rpm이 바뀌면 회전에서 생기는 성분의 위치도 움직인다
- 공진·배경 잡음 같은 고정 성분은 제자리에 있다

VS

차수축 (order)

- 주파수를 회전 주파수로 나눈다
- rpm이 바뀌어도 회전 성분이 **같은 차수**에 고정된다
- 회전과 무관한 판별 정보는 흐려질 수 있다

입력 구성 (센서 1개당)	특징 수
기본 4피처 + rpm	5
절대축 확장 특징	12
차수축 확장 특징	12
합계 × 센서 3개	**29 × 3 = 87채널**

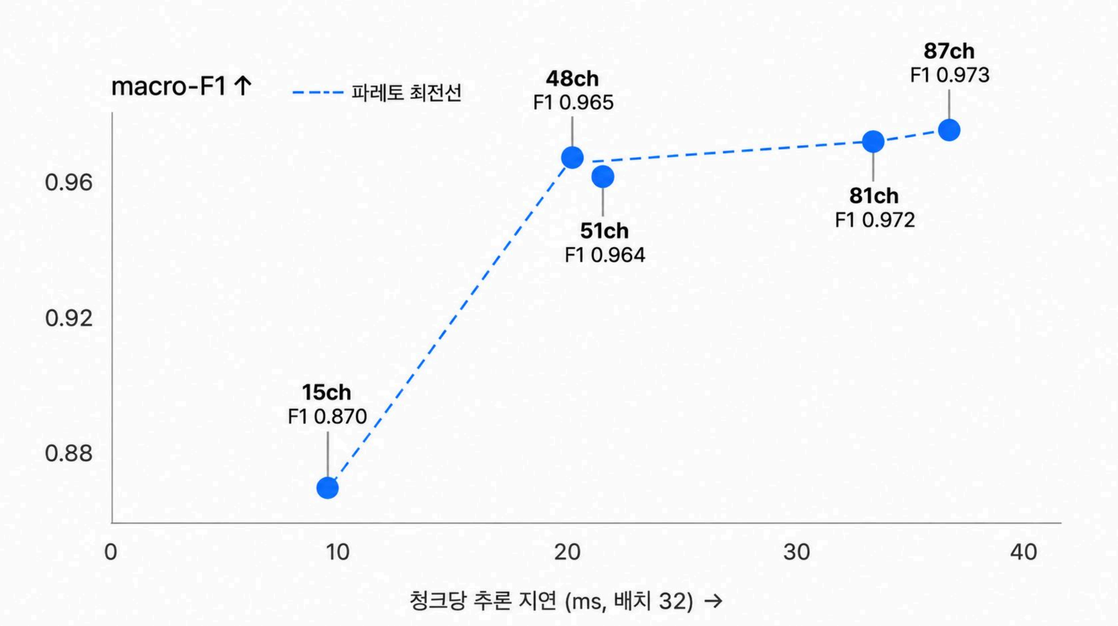


2-4. 차수축 결합 결과

두 축을 합친 87채널이 0.973으로 가장 좋았고, 이는 채널 수가 아니라 두 축이 서로 보완했기 때문이다

구성	macro-F1	DEMAG 재현율
51ch 절대축만	0.9635	0.9275
51ch 차수축만	0.9562	0.9225
87ch 두 축 결합	**0.9729**	**0.9551**

- **같은 채널 수 비교** — 51채널끼리는 절대축이 차수축보다 조금 나았다
- **결합 효과** — 두 축을 합치자 두 지표 모두 가장 높았다



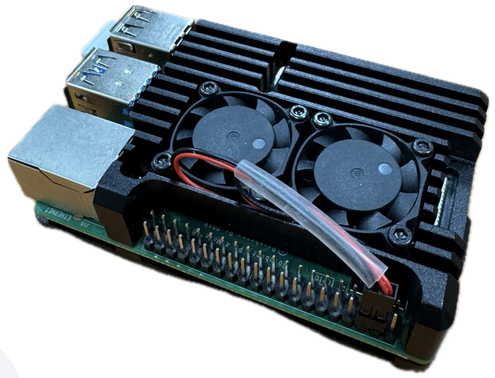
차수축은 오경보가 많고, 절대축은 미검출이 많아,
두 축을 결합하여 서로의 약점을 보완했다

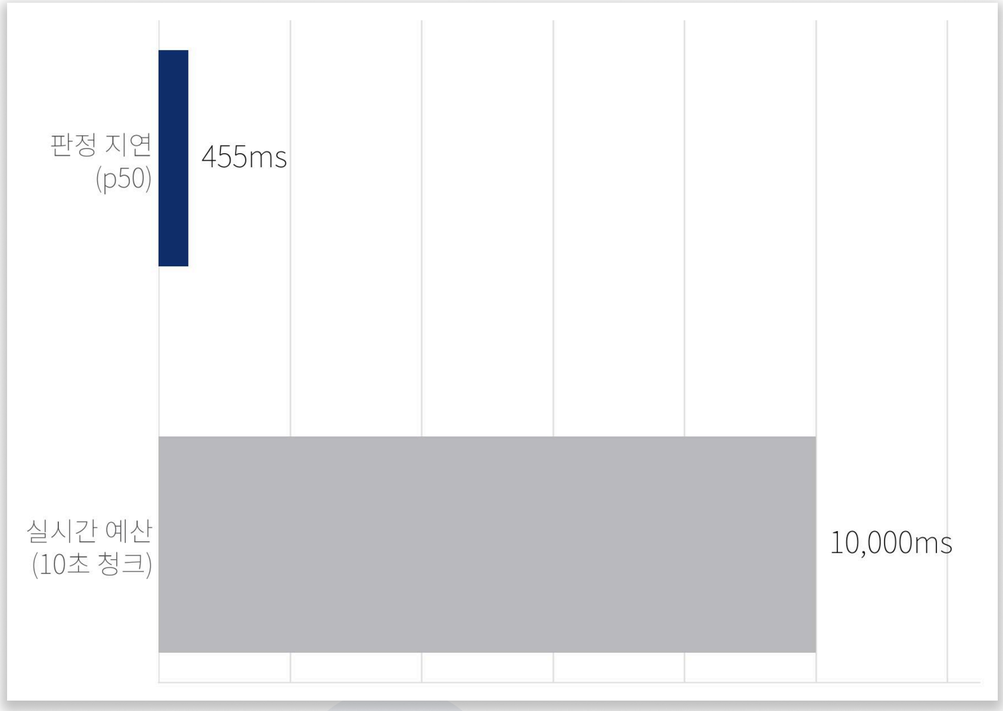
2-5. 라즈베리파이 4 실측 결과

최종 87채널 모델은 라즈베리파이 4에서 10초 신호를 455ms에 판정해, 실시간 예산보다 22배 빨랐다

측정 항목	결과
판정 지연	**455ms**
실시간 예산 대비	10,000ms(10초 청크)의 약 22분의 1
지연 구성	MiniRocket 452.1ms · 전처리 1.35ms · 분류기 1.57ms

> 측정 범위: MiniRocket과 분류기 구간이며, STFT·특징 추출 시간은 포함하지 않았다





판정 지연과 실시간 예산

3. 메타데이터 활용

Metadata Fusion

3-1 메타데이터란: Other 폴더

3-2 메타데이터 결합 결과

3-1. 메타데이터란: Other 폴더

AI-Hub는 센서 이미지와 별도로 Other 폴더에 측정 당시의 토크·회전수·온도 기록을 함께 제공한다

- **CSV** — 센서를 측정할 때 차량의 운전 상태를 기록한 데이터
- **짝 관계** — CSV 1개가 센서 PNG 10초 조각 1개와 짝을 이룬다. 학습에 쓴 146,880개 조각이 모두 연결됐다
- **요약 특징** — 파일마다 5개 신호 × 5개
  기초 통계량(평균·표준편차·최솟값·최댓값·고유값 수) = 25개를 만들었다

신호	의미	단위
torque_ref	목표 토크	Nm
torque_act	실제 토크	Nm
rpm	**모터 회전속도**	**rpm**
temp_inv	인버터 온도	°C
temp_motor	모터 온도	°C

> rpm은 이미 모델 입력에 쓰이고 있었다

3-2. 메타데이터 결합 결과

메타데이터 통계를 87채널 모델에 붙여도 최대 +0.058%p이므로 개선으로 볼 수 없다

- **결합 방법** — MiniRocket이 만든 특징 벡터 뒤에 메타데이터 통계를 이어 붙여 분류기에 넣었다
- **비교 설계** — 같은 표본·같은 폴드(3차종 × 3폴드)에서 4개 구성을 비교했다
  - 신뢰구간은 주행 세션 단위로 2,000번 다시 뽑아 구했다

구성	macro-F1	기준 대비	95% 구간(%p)
기준 87ch	0.97366	—	—
+ 모터 온도	0.97369	+0.004%p	[−0.061, +0.068]
+ 토크 통계	0.97398	+0.033%p	[−0.038, +0.111]
+ 회전수 변동 통계	0.97400	+0.035%p	[−0.039, +0.111]
+ 메타데이터 전체 25개	**0.97423**	**+0.058%p**	**[−0.049, +0.173]**

해석 신뢰구간이 음수부터 양수까지 걸쳐있기 때문에, 기준 모델보다 좋게 나올수도, 안 좋게 나올 수도 있다.

4. AI Hub 모델과 비교

Fair Benchmark

4-1 기존 99.65%에는 데이터 누수가 있었다

4-2 공정 비교 결과

4-1. 기존 99.65%에는 데이터 누수가 있었다

AI Hub가 공개한 99.65%는 같은 측정 세션이 학습과 테스트에 함께 들어간 상태(**데이터 누수**)에서 나온 수치이다

기존 평가: 무작위 분할

- 10초 조각을 무작위로 8:1:1로 나눴다
- 같은 세션의 조각이 학습·테스트 양쪽에 들어갔다
- 테스트 측정 1,066개 중 **1,063개(99.72%)**가 학습에도 있었다

VS

공정 평가: 세션 단위 분할

- 측정 세션째로 학습·검증·테스트에 나눴다
- 세션 중복은 **0개**이다
- 모델이 처음 보는 주행으로만 채점했다

- **AI Hub 모델** — 센서 이미지 3장을 받아 고장 분류와 픽셀 단위 결함 영역 분할을 함께 학습하는 DeepLabV3+ 기반 딥러닝 모델이다
- **누수의 영향** — 같은 주행의 연속 조각은 패턴이 거의 같아, 이미 본 주행을 다시 맞히는 셈이 되어 정확도가 부풀려진다

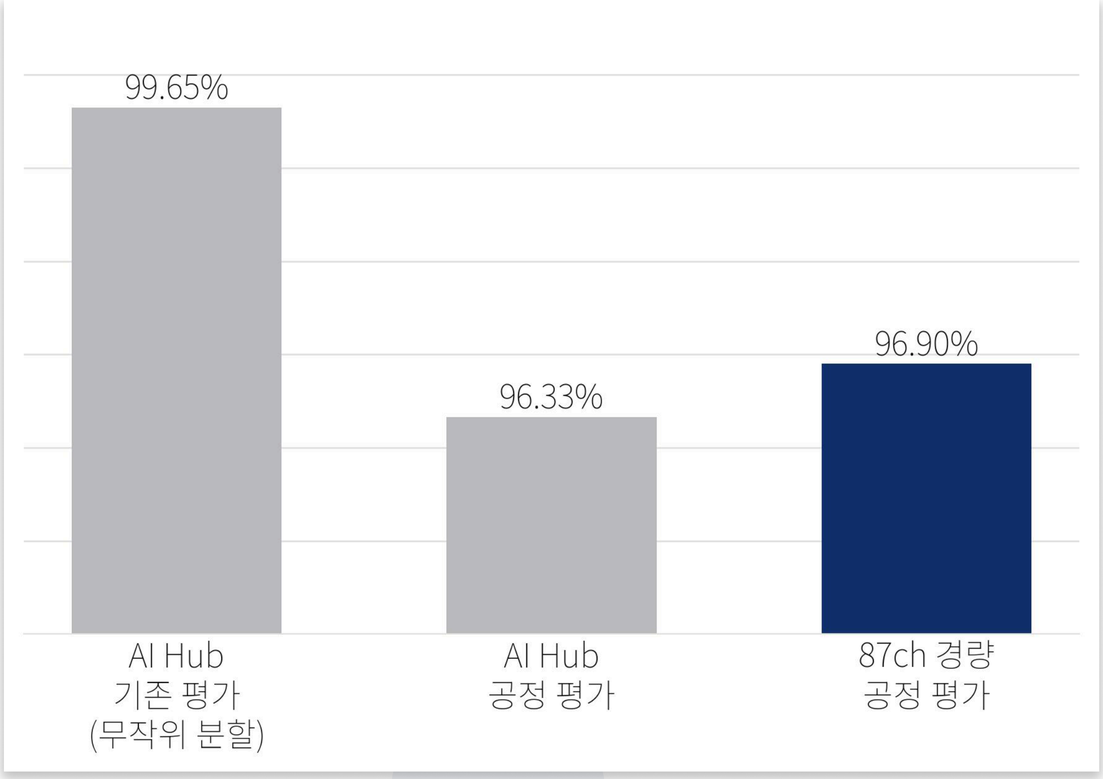
4-2. 비교 결과

동일한 조건에서 AI Hub는 **96.33%**로 내려왔고, 87채널 경량 모델은 96.90%로 91건을 더 맞혔다

지표	AI Hub	87ch 경량
정확도	**96.33%**	**96.90%**
Macro-F1	96.41%	97.06%
정답 수 / 16,046건	15,457	15,548
모델 크기 (3차종)	45.17MB	2.16MB

- **차이** — 경량 모델이 정확도 +0.57%p, Macro-F1 +0.64%p 높았다
- **통계적 해석** — 세션 단위 95% 신뢰구간이 −0.43~+1.58%p 이다
  - 현재 실험 결과만으로는 두 모델의 우열을 판단하기 어렵다

경량 모델은 약 **21분의 1 크기**로 **AI Hub 모델에 근접한 성능**을 보였다



정확도 비교 (기존 평가는 테스트 표본이 다름)

의사결정 경로 요약

다섯 번의 채택·기각을 거쳐 **87채널 MiniRocket + 로지스틱 회귀**를 최종 모델로 정했다

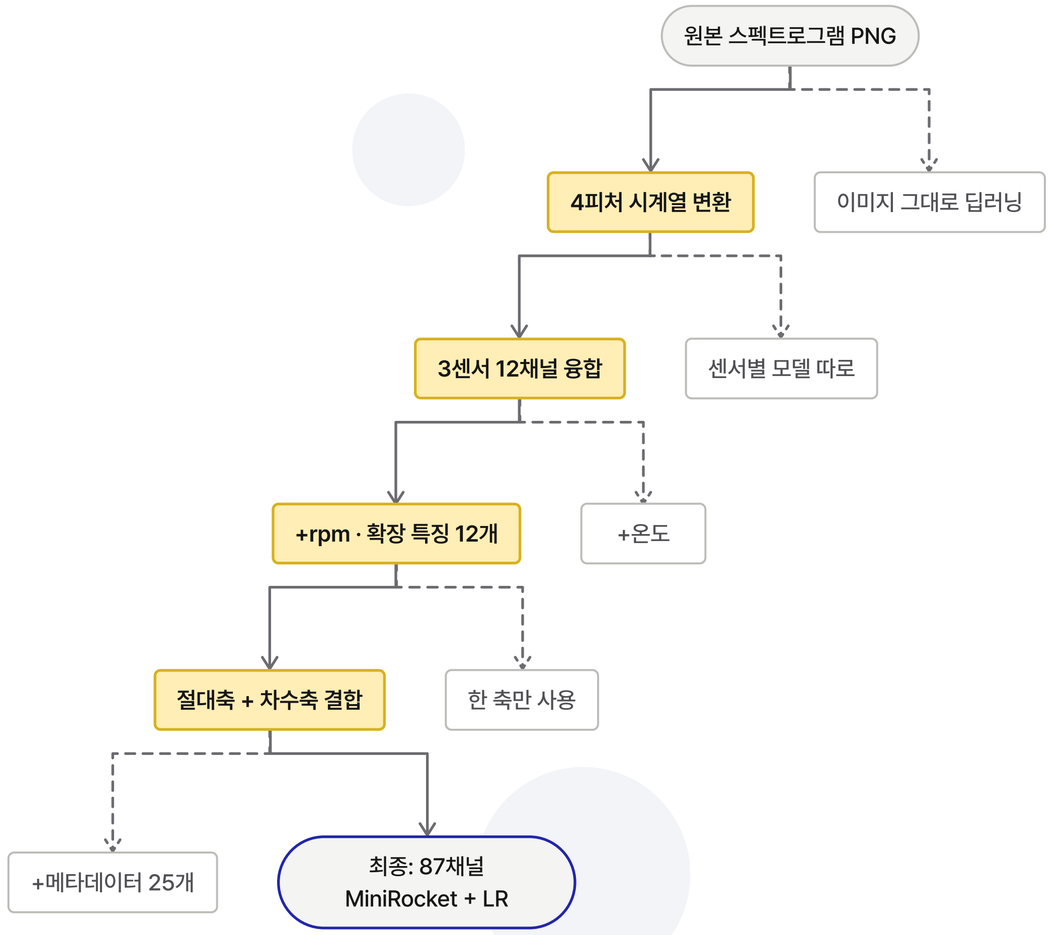
01 **입력 형태** — 이미지 → 4피처 시계열로 바꿨다
- 가볍고, 시계열 분류 모델을 바로 쓸 수 있다

02 **센서 결합** — 센서별 모델 → 3센서 12채널 융합을 택했다
- macro-F1이 세 차종 모두 0.20 안팎 올랐다

03 **추가 특징** — rpm과 확장 특징 12개는 채택, 온도는 기각했다
- macro-F1 0.874 → 0.964 (온도 추가 시 0.873)

04 **주파수 축** — 절대축과 차수축을 결합했다
- macro-F1 0.9635 → 0.9729, 두 축이 서로의 단점을 보완한다

05 **메타데이터** — macro-F1 +0.058%p, 신뢰구간이 0을 포함해 기각했다



5. 시스템 구현과 결론

Implementation & Conclusion

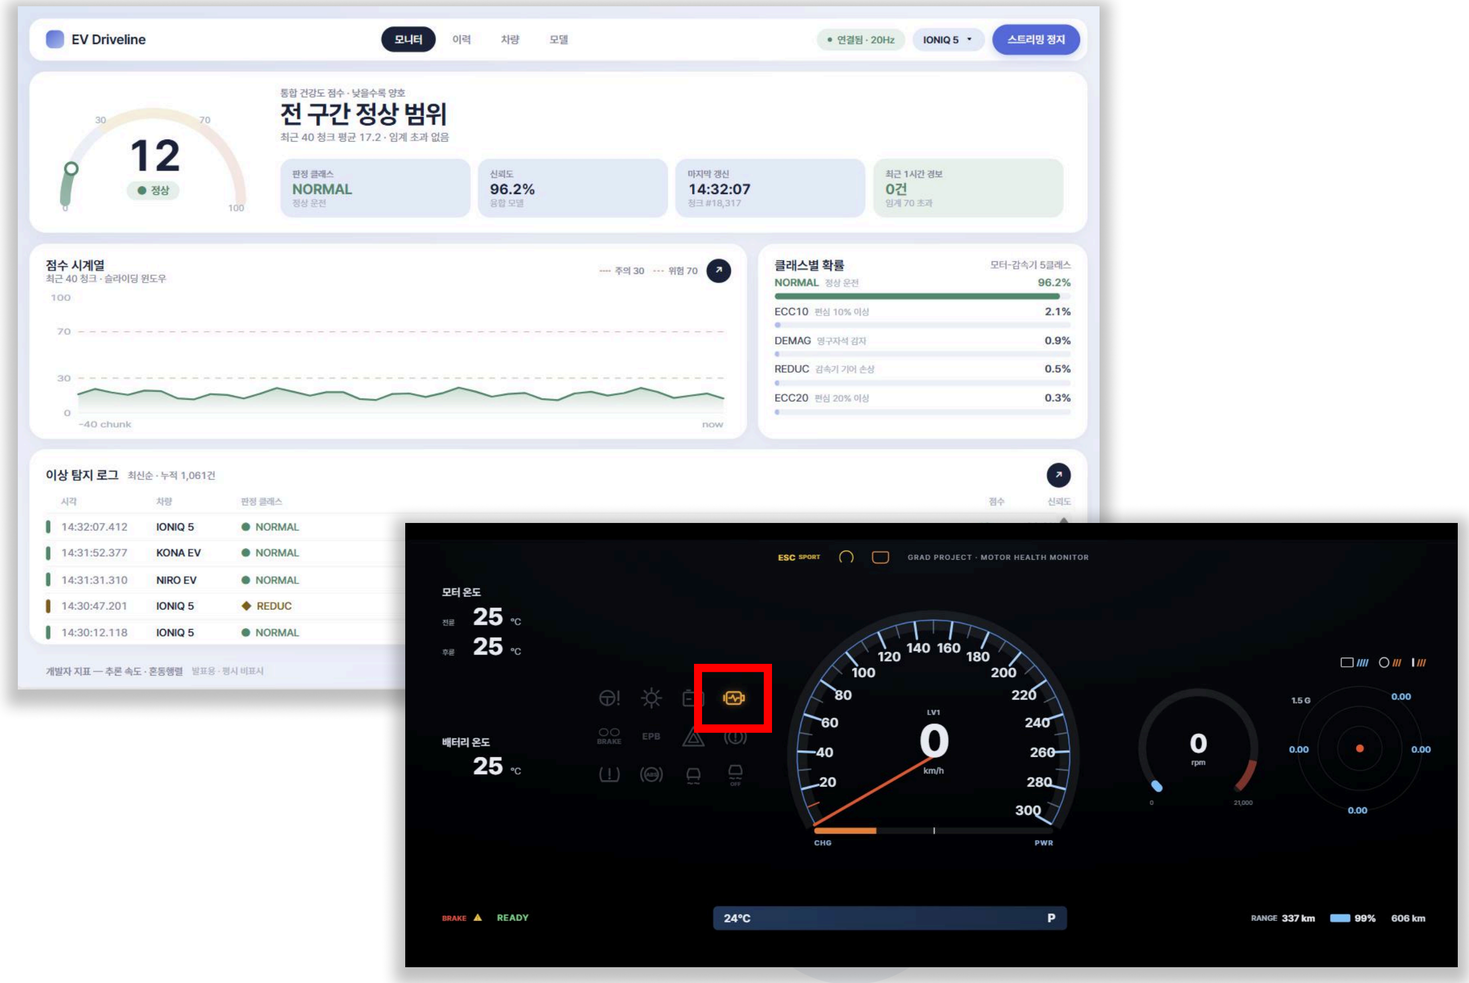
5-1 진단 결과 표시: 대시보드와 계기판

5-2 결론 및 향후 과제

5-1. 진단 결과 표시: 대시보드와 계기판

이상이 있을 때만 아이콘 색으로 알리도록 설계했다

- **웹 대시보드** — 정비사의 점검·진단을 지원한다
- **차량 계기판** — 운전자에게 차량 상태를 안내한다
  - 회색=정상, 주황=주의, 빨강=결함
- **설계 원칙** — 운전 중 주의를 빼앗지 않도록 이상이 있을 때만 강조한다



5-2. 결론 및 향후 과제

87채널 경량 모델은 공식 딥러닝 모델의 **약 21분의 1 크기**로 근접한 성능을 냈고, 라즈베리파이에서 실시간으로 동작했다

1학기 숙제에 대한 답

- **DEMAG↔NORMAL** — 확장 특징과 차수축으로 DEMAG 재현율을 0.955까지 올렸다
- **메타데이터** — 모델 입력으로 더해도 이득이 없었다. 회전수 정보는 이미 모델 안에 있었다
- **하드웨어 환경 실측 검증** — 차종당 0.69MB, 라즈베리파이 4에서 10초 신호를 455ms에 판정했다

한계와 다음 단계

- **AI Hub 비교** — 여러 seed와 3-fold 전체 검증으로 다시 확인한다
- **전처리 시간** — 원본 센서데이터가 없으므로 STFT 변환 시간 측정이 불가능하다
- **실차 적용** — 실제 차량에서 검증할 수 없다

감사합니다

질문 받겠습니다

박세진 · 박솔