

3 차 발 표

자율주행 전기차 모터-감속기 이상 징후 탐지 기술 경량화

원본 데이터 학습 및 성능 개선 결과

7조 · C321027 박세진 · C321028 박솔



연구배경

전기차 시장의 성장

글로벌 전기차 보급률이 빠르게 증가하며, 차량 안전성과 신뢰성에 대한 요구가 높아지고 있다.

자율주행 기술의 고도화

자율주행 시스템은 모터·배터리의 정밀한 상태 모니터링 없이는 안전한 운행을 보장할 수 없다.

실시간 예지 보전의 필요성

미세 결함을 사전에 감지하는 예지 보전 기술은 사고 예방과 유지보수 비용 절감에 직결된다.

활발한 AI기반 전기차 이상 탐지 기술 연구




한국교통안전공단은 운전자에 맞춤형 배터리 성능 정보를 제공하고, 전기차 안전성 확보와 자원순환에도 기여하는 **AI기반 전기차 배터리 관리체계 마련**을 본격 추진한다고 밝혔다.

한국교통안전공단, 「TS, AI 기술로 전기차 배터리 관리 효율성 높인다」, 2025. 08. 12.

Graphical Abstract – 2차 발표(Pilot Test)

샘플 데이터로 파이프라인 전 과정 검증




파이프라인 전 과정 동작 확인 완료

→ 본 데이터(원본 1.15TB)로 확장

Graphical Abstract – 2차 발표 이후

원본 데이터로 본격 학습



원본 데이터 경량화 결과

원본(PNG)

**1.15 TB**

경량화(CSV)

**107 GB**

90.7% 감소


기준 모델 — 센서별 9슬롯 학습 결과

차종 3 × 센서 3 = 9개 독립 모델

학습 구조

- 9개 슬롯 각각 독립 모델 학습
- MiniRocketMultivariate → LR (solver: saga)
- StratifiedGroupKFold(3분할) 교차검증

→ 차종 3 × 센서 3 = 9개 슬롯 (각 독립 학습)




기준 모델 — 센서별 9슬롯 학습 결과

차종 3 × 센서 3 = 9개 독립 모델


센서별 macro-F1

센서	macro-F1	비고
Vib_Motor	0.68~0.79	진동 · 구분 유리
Vib_TM	0.66~0.77	진동 · 구분 유리
Current_U	0.49~0.55	전류 · 상대적 낮음


Current_U




Vib_Motor




Vib_TM




KONA - Current_U




KONA - Vib_Motor




KONA - Vib_TM




NIRO - Current_U



NIRO - Vib_Motor



NIRO - Vib_TM



문제점 — 9슬롯 순차 처리로 약 28시간 소요

학습이 너무 오래 걸려 반복 실험·하이퍼파라미터 탐색이 어려움

개선 1 — 학습 소요시간 28시간 → 1시간 50분



슬버 교체

saga → lbfgs

수렴 경고를 해소하고
고차원 특징 학습 속도 개선



변환 결과 캐싱

.npz 캐시


MiniRocket 변환 결과 저장을 통해 재학습시
과정 생략



슬롯 병렬 학습

3개씩 병렬

내부 n_jobs=1로 제한
과점유 없이 3슬롯 동시 처리



15x
속도 향상

	학습 시간	macro-F1
기준 모델	약 28시간	0.63~0.67
개선 후	1시간 50분	동일

개선 2 — Late Fusion → Early Fusion (12채널)

센서 간 결합 패턴을 한 번에 학습


기존 방식 (Late Fusion)의 한계

- 센서별로 따로 예측한 뒤 확률을 합산
- 센서 간 결합 패턴을 활용하지 못함
- DEMAG는 진동+전류 조합으로만 구별되는 경우 존재

개선 방식 (Early Fusion · 12채널)

- 3개 센서(각 4피처) → 12채널 한 번에 입력
- 추가 검증: 12채널 융합 모델 3개 학습

차종별 macro-F1 — Late vs Early Fusion




IONIQ **+0.214**

KONA **+0.202**


NIRO **+0.198**

혼동행렬로 본 센서별·모델별 성능 차이


Current_U




Vib_Motor



Vib_TM



12채널 융합



1

전류 센서 (Current_U)

분류 성능이 가장 낮음.
DEMAG-ECC10-ECC20 간 상호 혼동이 크게 발생.

2








진동 센서 (Vib_Motor·TM)

ECC10-ECC20-REDUC는 높은 분류 성능을 보임
DEMAG ↔ NORMAL 혼동이 지속적으로 발생.

3

12채널 융합 (★12sum)

모든 차종에서 가장 높은 분류 성능을 기록
DEMAG → NORMAL 오분류가 절반 이하 감소.
DEMAG ↔ NORMAL 은 여전히 구분이 가장 어려움



결과 종합 — 3단계 개선의 성과

항목	기준 모델	속도 개선	융합 모델
입력 구성	센서별 4피처	센서별 4피처	3센서 12채널
결합 방식	late fusion	late fusion	early fusion
솔버	saga	lbfgs	lbfgs
학습 시간	약 28시간	1시간 50분	약 1시간 6분
macro-F1 평균	0.63~0.67	동일	0.83~0.87

16.5 ms

목표 추론시간(100ms) 대비 약 6배 빠른 속도

6.38 MB

센서별 모델 9개 합산

2.16 MB

융합 모델 3개

기존 연구 대비 개선점

기존 연구

이미지 세그멘테이션 모델을 활용한 실시간 전기차 모터-감속기 고장 진단법 (박병준, 한동석)

- 이미지 기반 스펙트로그램 · 약 1.15TB
- DeepLabV3+ 고성능 이미지 모델
- mIoU 0.99 · 성능 중심 평가
- 수백 ms 추론 · 데이터 누수 가능성



본 프로젝트

경량화 모델

- 시계열 특징 데이터 · 약 107GB (90% ↓)
- Early Fusion + LBFGS 경량 ML (2.16MB)
- Macro-F1 0.83~0.87
- 16.5ms 실시간 · 엣지 CPU 적용 가능

핵심

최고 성능보다 **실제 적용 가능성 확보**

남은 과제와 2학기 계획

1 DEMAG ↔ NORMAL 오분류 해결

2 배터리 이상 탐지 시작

3 하드웨어 환경 실측 검증

4 메타데이터 활용

☆ [RE][AI hub 데이터] 자율주행 고장진단 데이터의 Other 폴더 데이터 정보 관련해서 문의드립니다. 📧

보낸사람 김철 <kc@a-tech.kr>

받는사람 박세진

2026년 6월 11일 (목) 오후 5:51

안녕하세요. 에이테크 김철입니다.

1열 토크(reference) (Nm)
2열 토크(Actual) (Nm)
3열 모터 회전속도(rpm)
4열 인버터 온도 (°C)
5열 모터 온도 (°C)

입니다.

감사합니다.

```
=====
자 율 주 행 고 장 진 단 데 이 터 구 조
=====

전 체 데 이 터 셋 ..... 601G
|
+-- Other ..... 19G
|
+-- Training
|   +-- 원 천 데 이 터 ..... 578G
|   +-- 라 벨 링 데 이 터 ..... 462M
|
+-- Validation
|   +-- 원 천 데 이 터 ..... 4.0G
|   +-- 라 벨 링 데 이 터 ..... 58M
=====

(base) → ~ git:(main) ×
```

핵심 방향

고장 신호(Current, Vibration) 외에 운전 조건 정보를 **공변량(Covariate)**으로 활용하여 추가적인 분석 수행