MiniRocket AnomalyDetection LogisticRegression Classification Edge AI Lightweight

자율주행 전기차 모터-감속기 이상 탐지 기술 경량화

Lightweighting of Anomaly Detection Models
for Motor–Reducer Systems in Autonomous Electric Vehicles

C321027 박세진
C321028 박솔

2026.11

연구배경

1 전기차 시장의 성장

2026년 국내 전기차 누적 등록
100만 대를 돌파하며,
차량 안전성과 신뢰성에 대한 요구가 높아지고 있다.

2 자율주행 기술의 고도화

자율주행 시스템은 모터의
정밀한 상태 모니터링 없이는 안전한
운행을 보장할 수 없다.

3 차량내 예지 보전의 필요성

미세 결함을 사전에 감지하는 예지
보전 기술은 사고 예방과 유지보수
비용 절감에 직결된다.

4 활발한 AI기반 전기차 이상 탐지 기술 연구

과학기술정보통신부 · 한국지능정보사회진흥원(NIA)

정부는 AI Hub를 통해 IONIQ·KONA·NIRO 차량의
모터-감속기 고장진단 데이터 55만 건을 공개했다.

기아

기아는 운행 중 수집한 데이터로 전기차의 이상 징후를 미리 찾아,
고장 정보와 예상 수리 항목을 정비사에게 자동 전달하는 선제 진단 시스템을
2026년 하반기부터 시범 도입한다.

한국지능정보사회진흥원, 「자율주행 고장진단 데이터」, AI Hub, 2023. 12. 13. / 인더뉴스, 「기아, 전기차 이상 징후 미리 찾는다...선제 진단 시스템 시범 도입」, 2026. 08. 03.

선행연구의 한계

선행연구 파이프라인

AI Hub - Base Line Model

전류 전동 신호
모터-감속기

STFT PNG
2000×1280 고해상

DeepLabV3+
ResNet-50 기반 분할모델

99.6%
Accuracy mIoU 0.99

차량 내 적용 과제

1 **엣지 진단의 필요성**
차량 내에서 이상을 판단하므로
제한된 연산 자원에 맞는 설계 필요

2 **무거운 입력 모델**
고해상도 STFT 이미지와 분할 모델로 연산·메모리 부담

3 **실시간 성능 미검증**
정확도 외 모델 크기·추론시간 등 차량 내 적용 지표 미보고

기타 연구

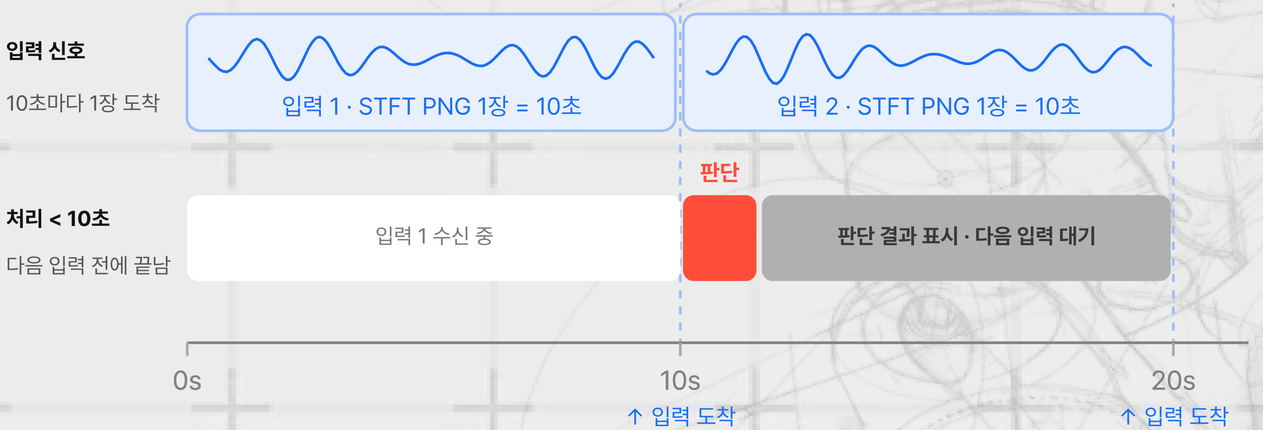
연구 제목	저자 및 연도	성능	사용 모델
Fault Diagnosis of EV Motor-Reducer Using High-Res Spectrogram	박병준, 한동석 (2024)	99.63%	**DeepLabV3+**: 모델이 무거움
Fault Diagnosis of In-wheel Motor EVs Using LSTM	이재훈 외 (2025)	98.7%	**LSTM**: NPU가속이 어려움
Deep Learning-based Instantaneous Fault Diagnosis	김형민 외 (2022)	99.1%	**CNN**: 연산량이 크고 메모리 많이 사용

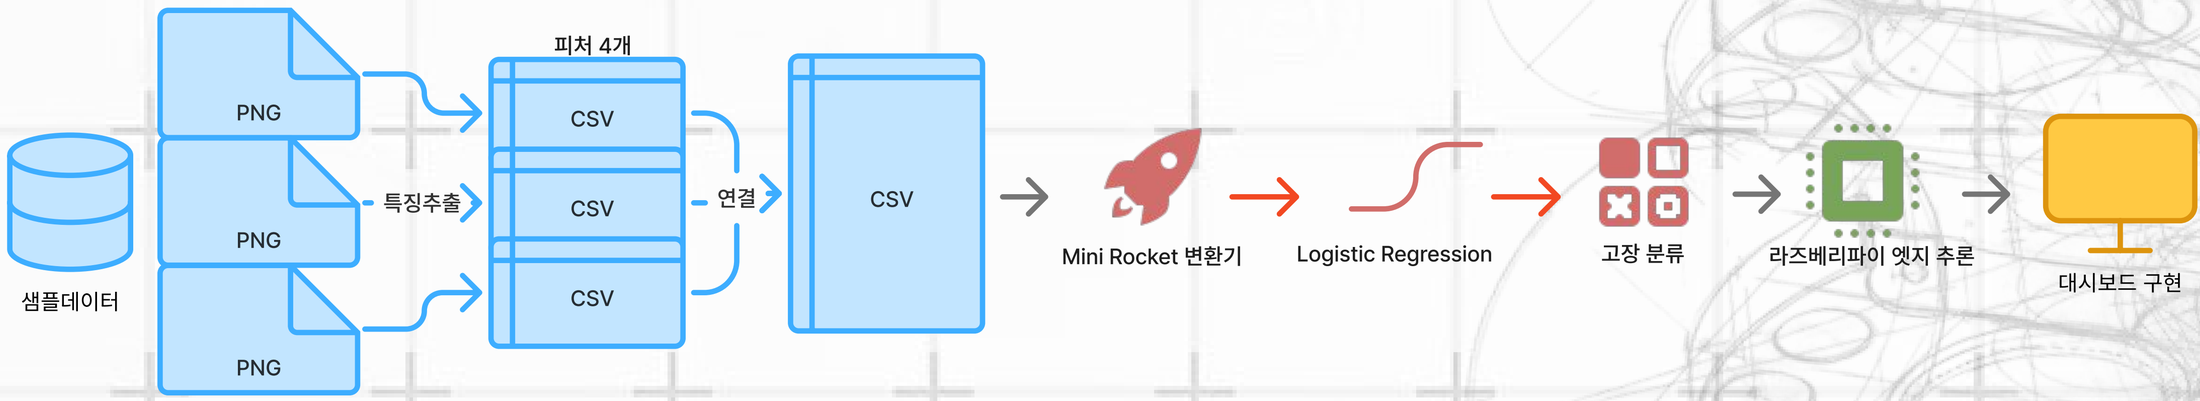
경량화 필요

연구 목표 및 요약

- **정확도** ..... 베이스라인 모델 수준
- **모델 크기** ..... MB단위
- **추론시간** ..... <10초

왜 10초?





데이터 개요

AI Hub 자율주행 고장진단 데이터

총 550,800건, 데이터 불균형 없음

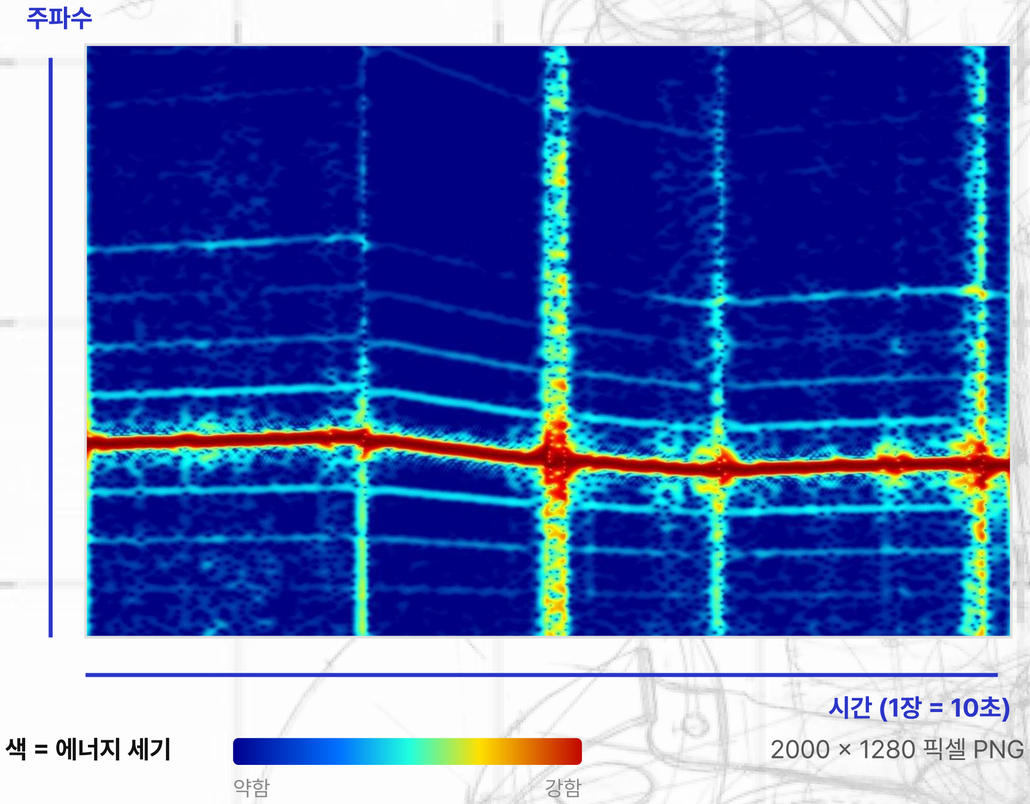
차량 종류
- IONIQ
- KONA
- NIRO

센서 종류
- Current_U 모터 전류(U상)
- Vib_Motor 모터 진동
- Vib_TM 감속기 진동

결함 유형
- DEMAG 감자_결함
- ECC10 편심_주의
- ECC20 편심_결함
- NORMAL 정상
- REDUC 감속기_기어_결함

STFT 스펙트로그램이란

신호를 짧은 구간으로 잘라 푸리에 변환(STFT)한 뒤, 시간에 따라 어떤 주파수가 얼마나 센지를 색으로 그린 이미지



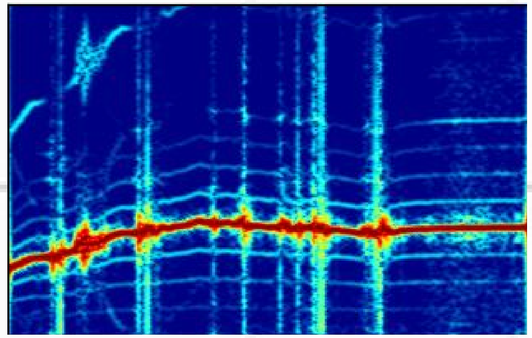
데이터 경량화

원본: 스펙트로그램 PNG

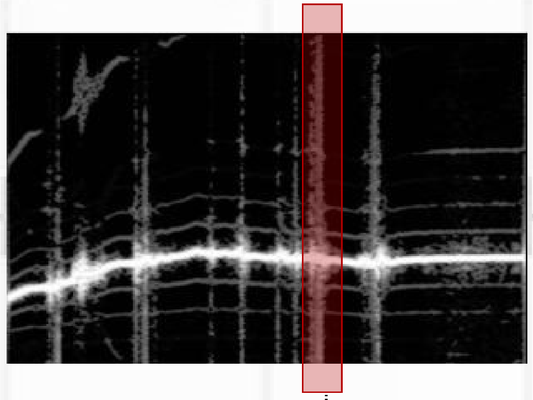
- 10초 조각마다 이미지가 1장
- 한 장이 2000 × 1280 픽셀
- 진단과 무관한 영역도 들어 있음

변환 후: 29피처 시계열

- 같은 측정의 조각을 이어 긴 신호로 복원
- 시점마다 특징 29개 저장
- 시계열 모델을 바로 쓸 수 있음



LUT변환



한 시점 당 특징 29개 추출

학습 방법

87피처 시계열 》 2,000행 청크 》 MiniRocket 변환 》 특징 벡터 》 로지스틱 회귀 》 5가지 상태 판정

센서
- 모터 전류(U상) 29피처
- 모터 진동 29피처
- 감속기 진동 29피처

→ 87피처

차종
- IONIQ
- KONA
- NIRO

→ 분류 모델 3개

MiniRocket

A Very Fast (Almost) Deterministic Transform for Time Series Classification

Rocket

수많은 무작위 합성곱(Convolutional) 커널을 사용해 시계열 데이터를 특징 벡터로 변환한 뒤,
간단한 선형 분류기에 통과시켜 빠르고 정확하게 분류하는 알고리즘

MiniRocket

무작위 컨볼루션 커널을 작고 고정된 결정론적 커널 세트로 대체하여 Rocket을 재구성
→ 무작위성을 크게 줄이고 상당한 속도 향상을 가능하게 함

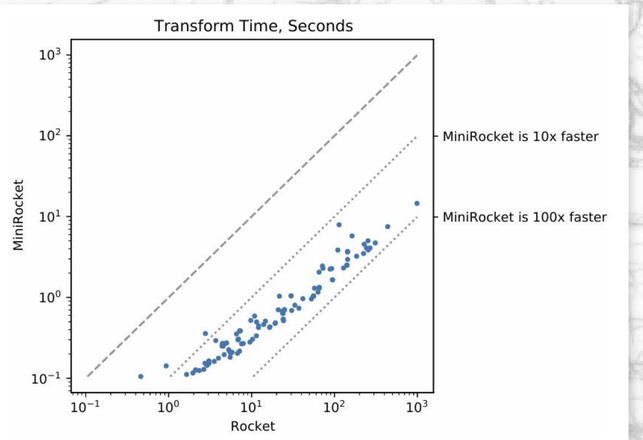


Figure 2: Transform time for MiniRocket versus Rocket for the same 109 datasets from the UCR archive.

Behind the Scenes

최종 모델이 만들어지기까지

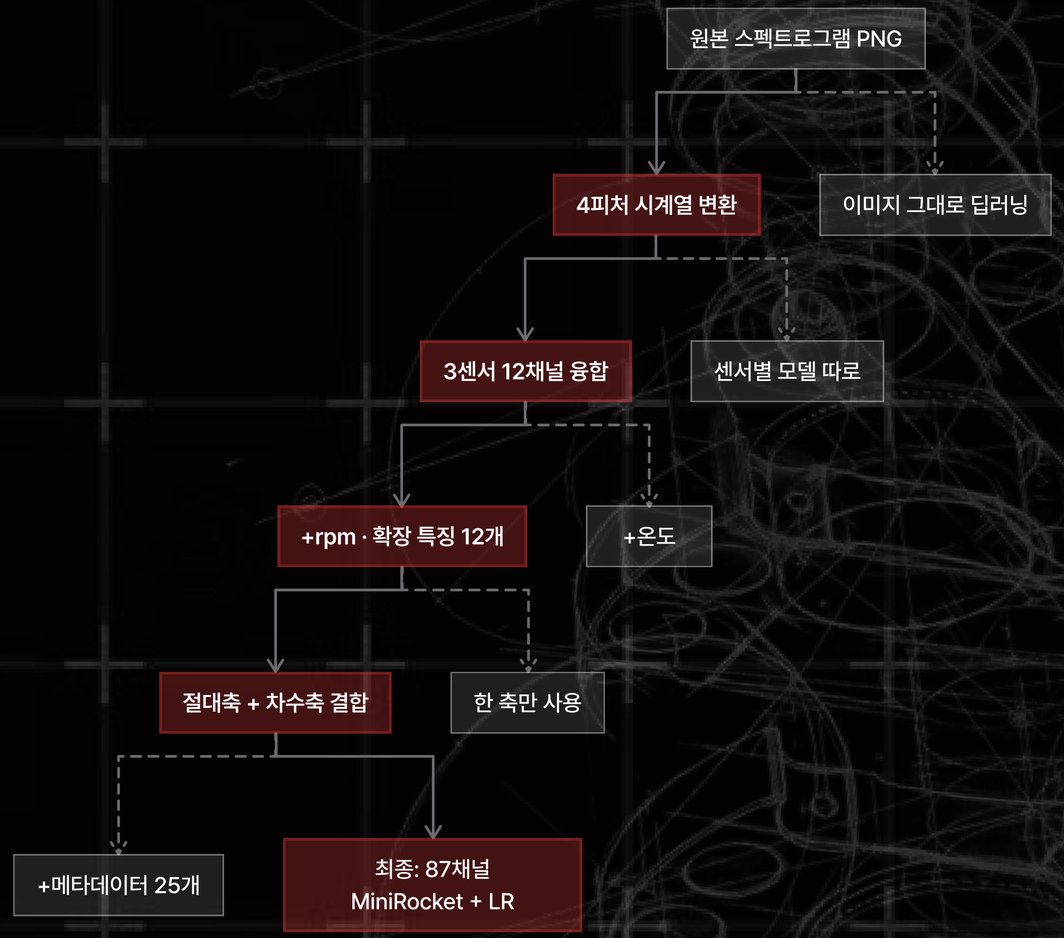
1 **입력 형태**
이미지 → 4피처 시계열

2 **센서 결합**
센서별 모델 → 3센서 12채널 융합

3 **추가 특징**
rpm과 확장 특징 12개는 채택, 온도는 기각

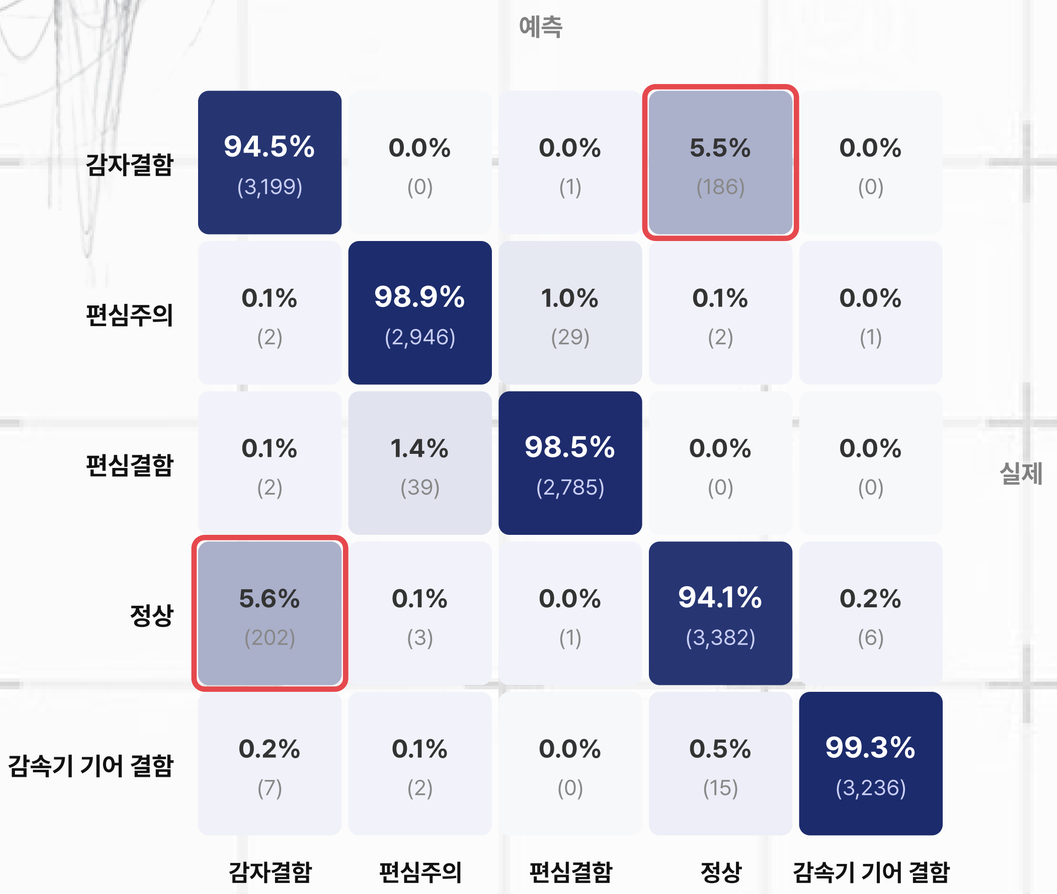
4 **주파수 축**
절대축과 차수축을 결합했다

5 **메타데이터:**
macro-F1 +0.058%p, 신뢰구간이 0을 포함해 기각했다



모델 학습 결과

혼동행렬



오분류 구성



감자결함 ↔ 정상	388건 (77.9%)
편심주의 ↔ 편심결함	68건 (13.7%)
기타	42건 (8.4%)

정확도
96.90%

macro-F1
97.06%

정답 수
15,548 / 16,046

오답 수
498건

BaseLine Model과의 비교

비교 전 BaseLine 모델의 데이터 누수 제거

기존 평가: 무작위 분할



- 10초 조각을 무작위로 8:1:1로 분리
- 같은 세션의 조각이 학습·테스트 양쪽에 포함
- 테스트 측정 1,066개 중 **1,063개(99.72%)**가 학습에도 포함

공정 평가: 세션 단위 분할



- 측정 세션째로 학습·검증·테스트 분리
- 세션 중복은 **0개**이다
- 모델이 처음 보는 주행으로만 평가

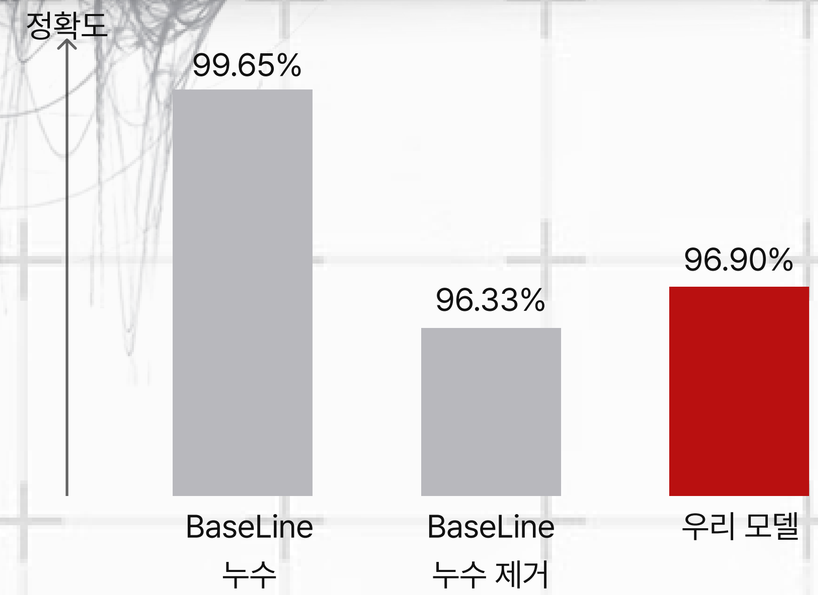
BaseLine 모델 정확도

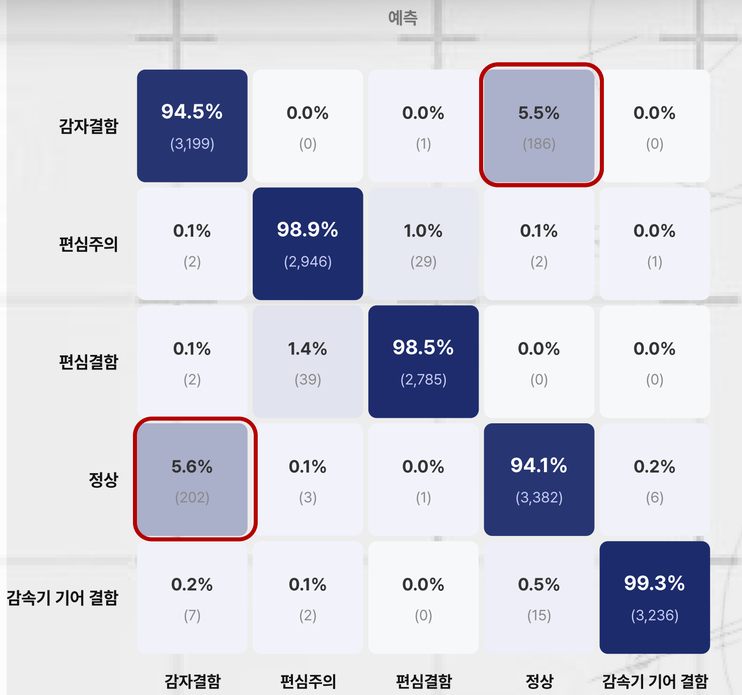
99.65%

누수 제거한 BaseLine 모델 정확도

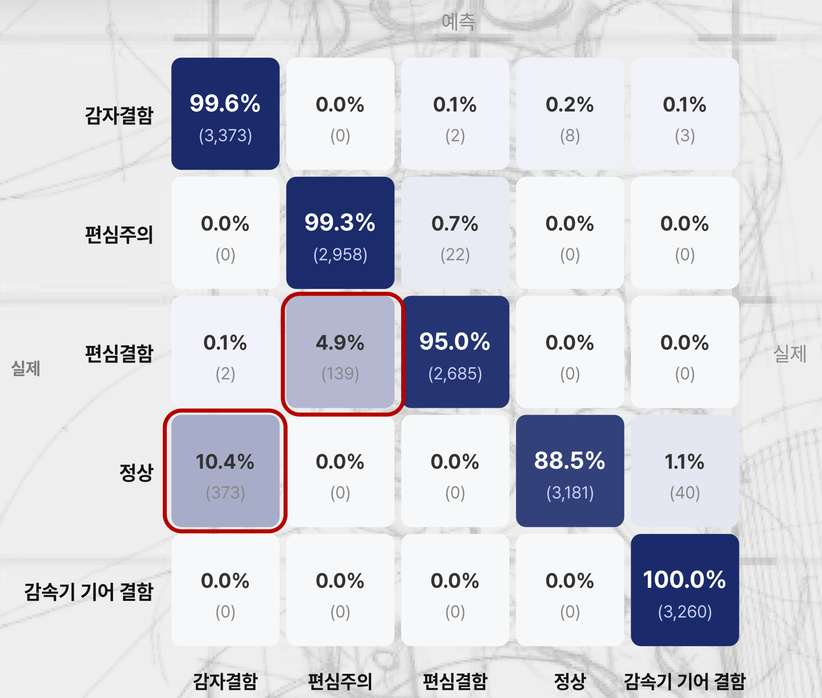
96.33%

BaseLine Model과의 비교





우리 모델



BaseLine 모델

H0 우리 모델 정확도 = BaseLine 모델 정확도

H1 우리 모델 정확도 ≠ BaseLine 모델 정확도

P-Value **0.288** >0.05

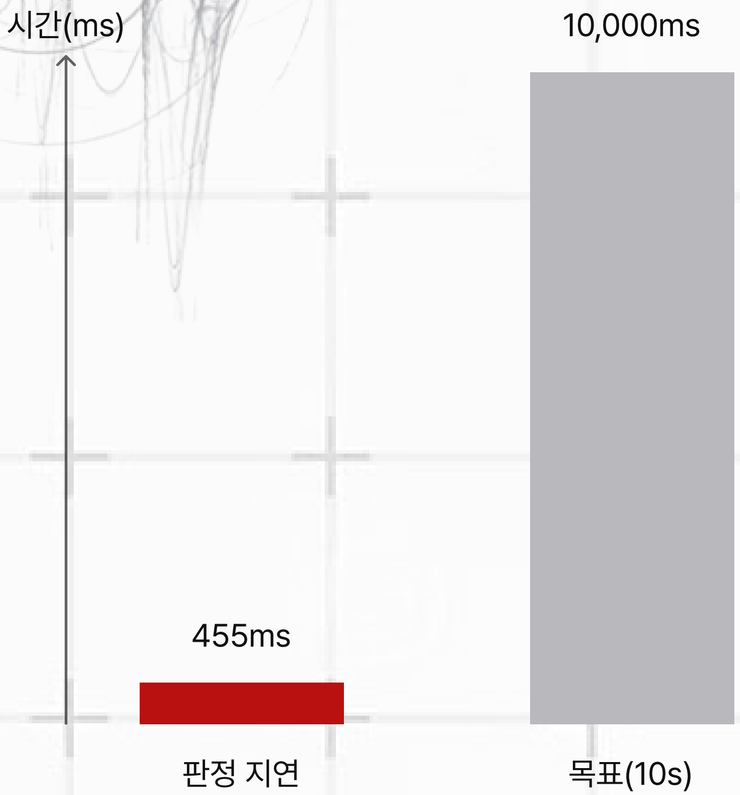
∴ **두 모델의 정확도에 유의미한 차이가 있다고 보기 어렵다**

감자결함 ↔ 정상 **0.1%p 증가**

편심주의 ↔ 편심결함 **1.6%p 감소**

엣지 환경 구동 검증

Raspberry Pi 4 실측 결과

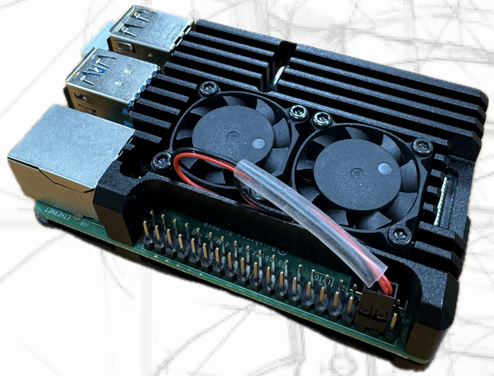


지연 구성

455.02ms

- MiniRocket 452.1ms (99.36%)
- 전처리 1.35ms (0.30%)
- 분류기 1.57ms (0.35%)

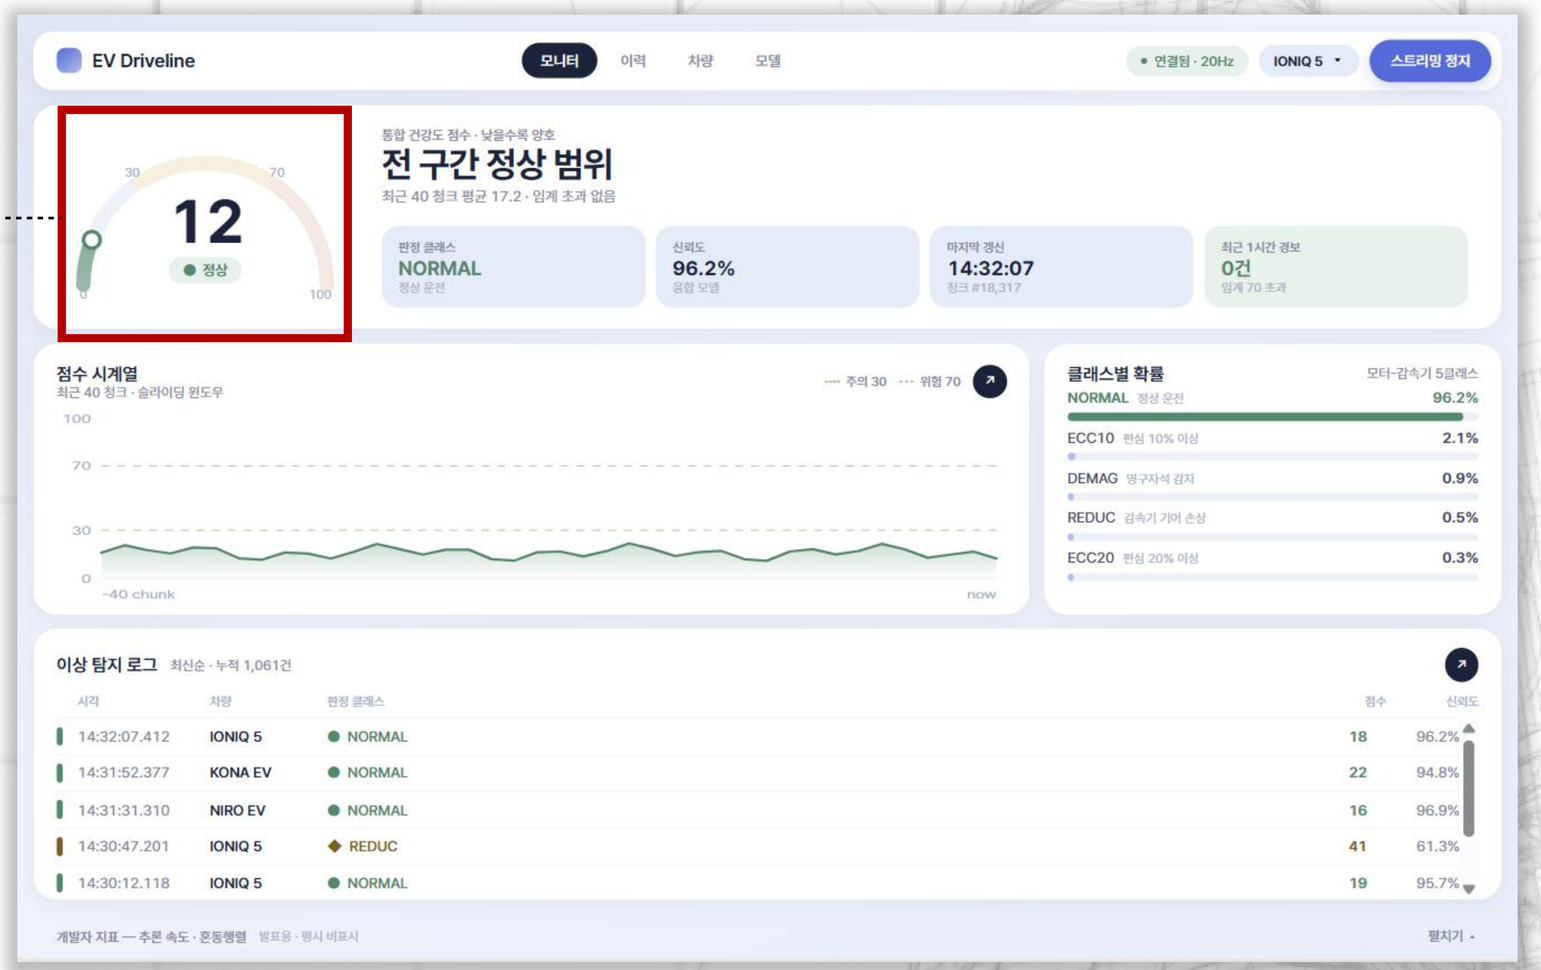
Raspberry Pi®



대시보드

- 정비사의 점검·진단을 지원한다
- **Anomaly Score: 1-P(Normal)**

정상 0~30
주의 30~70
결함 70~100



계기판

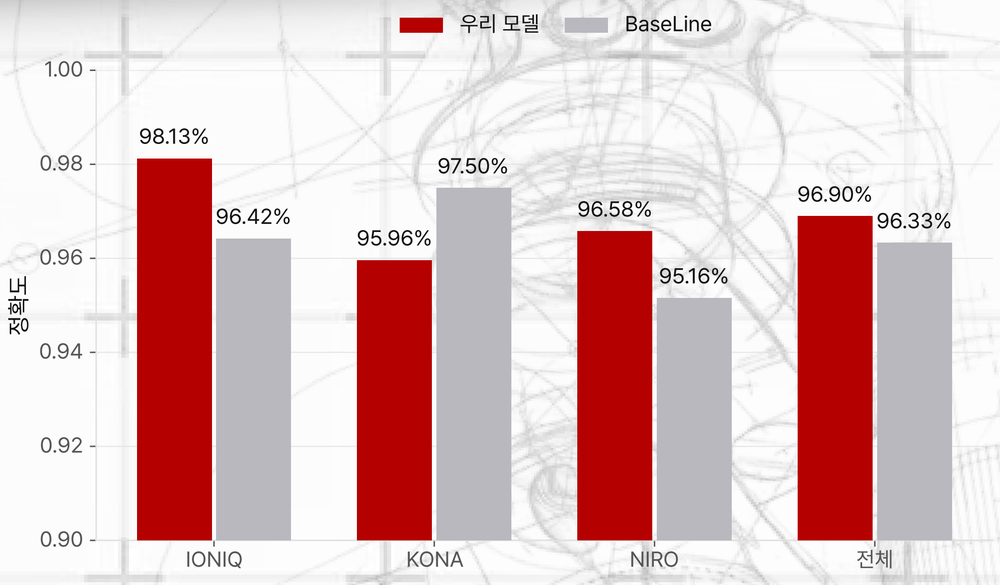


회색=정상, 주황=주의, 빨강=결함

- 운전자에게 차량 상태를 안내한다
- 운전 중 주의를 빼앗지 않도록 이상이 있을 때만 강조한다

결론

	Before	After	차이
데이터 크기 경량화	1.15TB	107GB	**-90.8%**
정확도 유지	96.33%	96.90%	**-0.43 ~ +1.62%p**
모델 경량화	45.17MB	2.17MB	**-91.7%**



향후 개선 방향

1. 센서데이터 → STFT 변환 시간 측정
2. 실차 적용 가능성 확인