

[박세진:C321027] 프로젝트 결과보고서

팀명/프로젝트명		7 조/자율주행 전기차 모터 및 배터리 이상 징후 탐지 기술 경량화		
팀	이름	역할	프로젝트 진행시 주요활동	기여도
본인	박세진	팀장	아이디어 제시, 문제 해결, 코드작성	5
팀원	박솔	팀원	아이디어 제시, 문제 해결, 코드작성	5
내용	1. 배경 및 진행 경과			
	1.1. 배경			
	자율주행 기술이 고도화되고 전기차 시장이 성장하면서 자동차는 컴퓨팅 디바이스로 변모하고 있다. 김말희 외(2025)의 연구에 따르면, 인공지능 기술의 확산에 따른 에너지 소비 문제는 환경적 영향과 경제적 부담을 동시에 초래하고 있으며, 특히 실시간 반응이 중요한 자율주행 분야에서는 엣지 AI를 통한 연산 최적화가 대안으로 제시되고 있다. 기존의 자율주행 고장 진단 베이스라인 모델로 활용되던 DeepLabV3+나 LSTM 기반 모델들은 높은 정확도를 보여주지만 파라미터 수가 방대하고 연산량이 커서 실시간 추론이 어렵다는 한계가 있다. 따라서 차량 내 디바이스에서 독립 구동 가능한 경량화된 이상 탐지 기술 개발이 필요하다.			
	1.2. 진행 경과			
	모터-감속기 데이터는 규모가 크고 전처리·모델링 과정에서 검토해야 할 사항이 많아, 배터리 진단은 후순위로 미루고 모터-감속기 이상 탐지에 역량을 집중하였다. 계획서 제출 이후의 진행 경과는 다음 여덟 단계로 요약된다.			
	- 모터-감속기 데이터 자체의 경량화 및 변환 방법 탐색 - 경량화된 데이터에 적합한 모델과 학습 방법 재선정 - 샘플 데이터를 이용한 파일럿 테스트(데이터 경량화부터 대시보드까지) - 원본 데이터 다운로드 및 압축 해제 - 원본 데이터 경량화 - 파일럿과 동일한 방식의 모델 학습 및 평가(기준 모델) - 학습 속도를 개선한 방식으로 재학습 및 재평가 - 분류 성능 향상을 위한 입력 형식·모델 구조 변경 및 평가			
	2. 프로젝트 주요 내용			
	2.1 데이터 경량화 및 변환 방법 탐색			
	먼저 10초 단위로 분할된 PNG들을 다시 이어 붙여 하나의 긴 시계열로 재구성하였다. AI-Hub가 제공하는 PNG는 연속 측정 신호를 일정 간격으로 잘라 놓은 것이므로, 같은 측정 구간의 조각들을 연결하면 원래의 연속 신호에 가까운 형태를 복원할 수 있다. 이렇게 긴 시계열로 만들면 시계열 분류 모델을 그대로 적용할 수 있고, 시계열을 일정 길이의 청크로 나눠 학습하면서 청크 크기를 바꿔 가며 실험할 수 있으며, 다양한 시계열 샘플링 기법도 활용할 수 있다. 즉, 신호를 연결하는 것만으로 분석의 자유도가 크게 넓어진다고 판단하였다. 또한 원본 PNG는 용량이 크고 모든 영역이 진단에 유효한 정보를 담고 있지 않으므로, 핵심 정보만 추려 내는 경량화가 필요하다고 보았다.			
	PNG 연결: 차종, 고장 유형, 센서, 측정 시각, zsplit 번호가 모두 일치하고 10초 단위 분할 번호가 연속인 PNG들을 하나로 이어 붙였다.			
	CSV 변환: 이어 붙인 PNG 한 장을 CSV 한 개로 변환하면서 스펙트로그램에서 다음 정보를 추출하였다. ① 각 시간 인덱스에			

서 에너지가 가장 큰 주파수 bin의 위치(peak_freq_bin), ② 활성 주파수 대역의 시작과 끝(band_start, band_end), ③ 신호 에너지의 크기를 나타내는 RMS 값이다. 대역 정보가 시작·끝 두 컬럼으로 나뉘므로 최종적으로 한 시점당 4개의 피치가 만들어진다.

2.2 모델 및 학습 방법 재선정

모델 선정: 계획서 단계에서는 PNG를 이미지 그대로 모델에 입력하는 방식을 가정했으나, 데이터를 4피치 시계열 CSV로 바꾸면서 시계열에 적합한 새로운 분류 방법이 필요해졌다. 이에 MiniRocket을 도입하였다. MiniRocket은 시계열을 다수의 고정된 합성곱 커널로 한 번에 변환한 뒤, 각 커널 출력에서 양의 값 비율(PPV) 같은 간단한 통계를 뽑아 고차원 특징 벡터로 요약하는 시계열 변환 기법이다. 커널 파라미터가 대부분 사전에 정해져 있어 딥러닝처럼 무거운 학습이 필요 없고, 변환이 매우 빠르면서도 정확도는 최신 시계열 분류기에 견줄 만하다. 본 프로젝트는 MiniRocket의 다변량 버전(MiniRocketMultivariate)으로 4피치 시계열을 특징 벡터로 변환한 다음, 가벼운 로지스틱 회귀(Logistic Regression)로 5개 고장 클래스(DEMAG-ECC10-ECC20-NORMAL-REDUC)를 분류하는 구조를 채택하였다.

학습 방법: 센서 3종 × 차종 3종, 총 9개 슬롯에 대해 각각 별도의 모델을 구축하였다. 각 CSV는 2000행 단위의 청크로 잘라 고정 길이 시계열 샘플로 만들었는데, 청크 1개가 대략 원본 PNG 1장 분량에 해당한다. 이때 데이터 누수에 유의해야 한다. 같은 CSV에서 잘려 나온 청크들은 동일한 측정 환경에서 연속 기록된 신호의 서로 다른 구간이므로 패턴이 거의 같다. 따라서 한 시계열에서 나온 청크가 학습셋과 검증셋에 동시에 들어가면, 모델이 사실상 이미 본 신호를 검증하는 셈이 되어 성능이 부풀려진다. 이를 막기 위해 같은 CSV에서 나온 청크에는 동일한 group_key를 부여하고, 하나의 group_key는 학습셋과 검증셋 중 한쪽에만 배정되도록 하였다. 교차검증은 클래스 비율을 유지하면서 그룹 누수를 막아 주는 StratifiedGroupKFold(3분할)를 사용하였다.

2.3 샘플 데이터 파일럿 테스트

본격적인 작업에 앞서 AI-Hub가 제공하는 샘플 데이터로 데이터 경량화부터 대시보드 구현까지 전 과정을 축소 실행하여 파이프라인의 실현 가능성을 확인하였다.

2.4 원본 데이터 다운로드 및 압축 해제

파일럿으로 가능성을 확인한 뒤 AI-Hub에서 원본 데이터를 내려받아 압축을 해제하였다. 데이터 규모가 커 다운로드와 압축 해제 모두 장시간이 소요되었고, 그 과정에서 다음과 같은 시행착오를 겪었다. 처음에는 노트북에서 작업했으나 사양 한계로 파일이 손상되어 학교 컴퓨터로 환경을 옮겼다. 또한 2TB 외장하드를 준비했지만 압축 파일과 해제된 파일을 동시에 보관하기에는 용량이 부족하여, 압축 해제 대상을 내장 디스크로 변경한 뒤에야 정상적으로 풀 수 있었다.

2.5 원본 데이터 경량화

파일럿에서 검증한 방식과 동일하게, 원본 데이터를 PNG 연결 → 4피치 CSV 변환 절차로 경량화하였다.

2.6 모델 학습 및 평가(기준 모델)

파일럿과 동일한 방식(센서별 9개 슬롯, MiniRocket + 로지스틱 회귀)으로 원본 데이터를 학습하였다. 이 기준 모델의 슬롯별 macro-F1은 진동 센서(Vib_Motor-Vib_TM)에서 0.66~0.79, 전류 센서(Current_U)에서 0.49~0.55 수준으로 나타나, 진동 신호가 전류 신호보다 고장 구분에 더 유리함을 확인하였다. 다만 이 단계의 학습은 9개 슬롯을 순차 처리하는 데 약 28시간(wall time 1일 4시간 26분)이 걸려, 반복 실험에 큰 제약이 있었다.

2.7 개선 1 — 학습 속도

학습 시간이 지나치게 길어 실험 회전이 어려웠기 때문에, 이미 검증이 끝난 학습 본체는 그대로 두고 속도에 직접 영향을 주는 부분만 교체하였다. 첫째, 로지스틱 회귀의 최적화 솔버를 saga에서 lbfgs로 바꾸었다. 반복 횟수 부족 경고(ConvergenceWarning)의 실제 원인이 saga의 느린 수렴이었는데, lbfgs는 L2 정규화 로지스틱 회귀와 고차원 특징에서 훨씬 빠르게 수렴한다. 둘째, MiniRocket 변환 결과를 입력 데이터의 해시값을 키로 .npz 파일에 캐싱하였다. 솔버나 규제 강도 같은

분류기 설정만 바뀌 재실험할 때 무거운 특징 변환을 건너뛸 수 있어, 재실험이 수십 분 단위로 단축된다. 셋째, 슬롯 단위 학습을 3개씩 병렬로 실행하되 MiniRocket 내부 병렬은 1로 낮춰, 바깥 병렬과 안쪽 병렬이 코어를 중복 점유하는 비효율(oversubscription)을 피했다. 그 결과 동일한 9개 슬롯 학습이 약 28시간에서 1시간 52분으로 줄어, 정확도 손실 없이 약 15배의 속도 개선을 얻었다.

2.8 개선 2 — 분류 성능(12채널 융합)

기준 모델은 센서별로 따로 학습한 뒤 확률을 사후에 합치는 방식(late fusion)이어서, 센서 간 결합 패턴과 고장별 가중치 차이를 활용하지 못하는 한계가 있었다. 예컨대 어떤 고장은 전류와 진동 패턴이 함께 나타나는 조합으로만 구별되는데, 센서를 따로 예측하면 이러한 결합 정보를 쓸 수 없다. 이에 한 측정 세션의 3개 센서(각 4피처)를 12개 채널로 쌓아 하나의 샘플로 입력하는 early fusion 방식을 도입하였다. MiniRocketMultivariate는 채널 수에 무관하게 동작하므로 코드 변경은 크지 않았다.

다만 3개 센서를 채널로 쌓으려면 센서들이 시간적으로 정렬되어 있어야 하므로, 먼저 정렬 상태를 점검하였다. 전체 12,720개 세션 모두에서 3개 센서가 빠짐없이 존재했고(누락 0건), 센서별 길이도 190,000행으로 동일하여 잘라내기 없이 손실 없는 융합이 가능했다. 차종별 융합 가능 세션은 IONIQ 5,229개, KONA 3,707개, NIRO 3,784개였다. 융합 모델을 차종별로 학습한 결과 macro-F1이 IONIQ 0.871, KONA 0.874, NIRO 0.826으로, 기준 모델 대비 크게 향상되었다.

3. 프로젝트 결과물

세 가지 학습 방식(기준 모델 → 속도 개선 → 분류 성능 개선)의 핵심 차이를 정리하면 다음과 같다.

항목	기준 모델(2.6)	속도 개선(2.7)	융합 모델(2.8)
입력 구성	센서별 4피처	센서별 4피처	3센서 12채널
결합 방식	late fusion	late fusion	early fusion
최적화 솔버	saga	lbfgs	lbfgs
학습 시간(9슬롯)	약 28시간	약 1시간 52분	약 1시간 6분
macro-F1(차종 평균)	0.63~0.67	동일	0.83~0.87

속도 개선(2.6→2.7)은 정확도를 유지한 채 학습 시간만 단축한 것이므로 분류 성능은 기준 모델과 같다. 실질적인 성능 향상은 입력 구성을 바꾼 융합 모델(2.8)에서 나타났다. 차종별로 late fusion과 early fusion의 macro-F1을 비교하면 다음과 같다.

차종	late(센서별 평균)	early(12채널 융합)	차이(early-late)
IONIQ	0.657	0.871	+0.214
KONA	0.673	0.874	+0.202
NIRO	0.628	0.826	+0.198

세 차종 모두 0.20 안팎의 큰 폭으로 향상되어, 센서 결합 정보를 함께 학습하는 것이 효과적임을 확인하였다. 특히 기준 모델에서 서로 자주 혼동되던 DEMAG(감자)와 NORMAL(정상) 클래스의 per-class F1이 크게 개선되었다. 예를 들어 IONIQ에서 DEMAG는 센서별 최고 0.56에서 융합 0.78로, NORMAL은 0.54에서 0.78로 올랐다. 이는 단일 센서로는 구분이 모호하던 고장을 여러 센서의 패턴을 종합해 더 정확히 가려낸 결과로 해석된다.

3.1 혼동행렬 분석

위 비교를 클래스 단위로 더 들여다보기 위해, 차종(행) × 센서(열) 구성으로 혼동행렬을 함께 살펴보았다. 각 행렬에서 행은 실제 클래스, 열은 예측 클래스이며 대각선이 정답이다. 맨 오른쪽 열(★12sum)이 12채널 융합 모델의 결과다.




그림 1. 차중(행) × 센서(열) 혼동행렬. 행은 실제, 열은 예측 클래스이며 대각선이 정답이다. 맨 오른쪽 열이 12채널 융합 모델(★12sum)이다.

전류 센서(Current_U)는 단독으로는 대각선이 전반적으로 흐릿하고, 특히 DEMAG-ECC10-ECC20가 서로 폭넓게 번진다. 예를 들어 IONI에서 실제 DEMAG 중 상당수가 ECC10(659건)·ECC20(726건)으로 새어 나가는 등, 전류 신호만으로는 고장 종류를 안정적으로 가려내지 못함을 보여 준다.

진동 센서(Vib_Motor-Vib_TM)는 ECC10-ECC20-REDUC를 잘 맞히지만, DEMAG와 NORMAL을 서로 크게 혼동하는 공통된 약점이 있다. IONI의 Vib_TM을 보면 실제 DEMAG 중 1,823건이 NORMAL로, 실제 NORMAL 중 1,782건이 DEMAG로 잘못 분류되어, 두 클래스가 거의 절반씩 뒤섞인다. 즉 진동 센서는 고장의 유형은 잘 구분하지만 감자 결함과 정상 상태의 경계를 잡는 데에는 한계가 있다.

융합 모델(★12sum)에서는 대각선이 뚜렷하게 진해진다. ECC10-ECC20-REDUC는 거의 완벽에 가깝고(IONI 기준 각각 3,602-3,618-3,988건), 진동 센서의 고질적 약점이던 DEMAG↔NORMAL 혼동도 크게 완화된다. IONI에서 DEMAG→NORMAL 오분류는 약 1,800건에서 873건으로, NORMAL→DEMAG는 1,782건에서 843건으로 절반 이하로 줄었다. 단일 센서가 놓치던 패턴을 여러 센서를 함께 보며 보완한 결과로, 앞선 macro-F1 향상이 어디에서 비롯됐는지를 행렬이 직접 보여 준다.

다만 DEMAG↔NORMAL은 융합 이후에도 여전히 가장 큰 잔여 오류로 남는다. DEMAG(감자)는 자석 성능이 서서히 저하되는 결함이라 진동·전류 신호가 정상 상태와 가장 닮아 있어, 본질적으로 분리가 가장 까다로운 쌍이기 때문으로 보인다. 세 차종 가운데 NIRO가 이 잔여 혼동이 다소 큰 편이다(DEMAG→NORMAL 994건, NORMAL→DEMAG 1,028건). 결국 혼동행렬은 융합 모델이 전 클래스의 정확도를 끌어올렸음을 확인해 주는 동시에, 남은 핵심 과제가 감자 결함과 정상 상태의 미세한 구분임을 분명히 드러낸다.

따라서 최종 결과물로는 12채널 융합 모델을 분류 판정에 사용하는 방향이 타당하며, 센서별 모델은 이상이 어느 센서에서 두드러지는지를 보여 주는 보조 지표로 함께 활용할 수 있다. 향후 과제로는 미뤄 둔 배터리 이상 탐지 모델링과, 확정된 융합 모델을 대상으로 한 양자화·지식 증류 기반 경량화를 진행할 예정이다.

3.2. 추론 시간

항목	값	비고
단일 청크 추론 지연	16.5ms	목표 ≤ 100 ms 충족 $\rightarrow$ 다운샘플링 불필요
센서별 모델 크기(9개 합산)	6.38 MB	model_registry.joblib
융합 모델 크기(3개)	2.16 MB	fusion_registry.joblib

경량화 목표였던 실시간 추론도 확인되었다. 청크 하나를 판정하는 데 걸리는 시간은 16.5 ms로, 기준선인 100 ms의 6분의 1 수준이라 추가적인 신호 다운샘플링 없이도 실시간 처리가 가능하다. 저장된 모델 역시 센서별 모델 9종을 모두 합쳐 6.38 MB, 융합 모델 3종이 2.16 MB로 매우 가벼워, 엣지 CPU 환경에 무리 없이 돌아갈 수 있다.

4. 2학기 시스템설계시 주요 계획

4.1. DEMAG $\leftrightarrow$ NORMAL 오분류 문제 해결

다음과 같은 해결 방법을 구상하였다.

- 피쳐 보강: 현재 4피쳐(peak_freq_bin, band_start, band_end, rms)는 "에너지가 어디에, 얼마나"에 가깝다. DEMAG(감자)는 특정 고조파 성분에서 미세하게 드러나므로, 회전 주파수의 정수배 대역 에너지 비율, 대역별 RMS 분리, 스펙트럼 엔트로피 같은 더 세밀한 피쳐를 추가해 정상과의 경계를 키운다.
- 2단계(계층) 분류: 1단계에서 NORMAL 대 이상을 가르고, DEMAG와 NORMAL만 따로 떼어 전용 이진 분류기를 둔다. 가장 헛갈리는 한 쌍에 모델 용량을 집중하는 방식이다.
- 결정 임계값·클래스 가중치 조정: 예측이 NORMAL 쪽으로 쏠리는 경향을 비용 민감 학습이나 임계값 튜닝으로 보정한다.
- 오분류 샘플 직접 분석: DEMAG $\leftrightarrow$ NORMAL로 틀린 청크가 어떤 운전 조건(rpm·부하)에서 물리는지 들여다본다
- 메타데이터 결합: 부하·회전수 정보로 신호를 정규화하면 DEMAG의 미세 차이가 더 뚜렷해질 수 있다.

4.2. 메타데이터 활용

토크(reference)(Nm), 토크(Actual)(Nm), 모터 회전속도(rpm), 인버터 온도($^{\circ}$ C), 모터 온도($^{\circ}$ C) 정보가 있는 csv데이터를 활용해볼 계획이다.

- 운전 조건 정규화: 진동·전류 신호는 rpm과 부하(토크)에 강하게 좌우되어, 같은 고장도 조건에 따라 모양이 달라진다. rpm·토크로 신호를 정규화하거나 조건 구간별로 나눠 보면 고장 신호가 더 선명해진다. 특히 DEMAG처럼 미세한 결함에 효과적일 수 있다.
- 토크 추중 오차(reference - actual): 명령 토크를 실제 토크가 못 따라가는 정도는 그 자체가 이상 징후로, 감속기 기어 결함(REDUC)이나 부하 이상의 단서가 된다.
- 온도(인버터·모터): DEMAG는 자석이 약해져 같은 토크를 내려면 전류를 더 흘려야 하므로 발열 패턴이 달라질 수 있다. 온도가 DEMAG 판별의 보조 단서가 될 가능성이 있다.
- 결합 방법: 이 메타데이터도 시계열이므로, 청크 단위로 통계(평균·표준편차·추세)를 요약해 정적 피쳐로 붙이거나 추가 채널로 쌓는다. 기존 12채널 융합에 자연스럽게 확장 가능하되, 센서 신호와 시간 정렬이 전제다.

4.3. 배터리 이상 탐지 시작

- 대상: NPY 수치 행렬(셀 96/98개의 전압·편차), 3클래스(NORMAL, 셀전압 결함, 셀편차 결함).
- 방법론 이식: 모터-감속기에서 검증한 "경량 데이터 $\rightarrow$ 가벼운 분류기" 워크플로우를 그대로 적용해 빠르게 1차 베이스라인을 만든다.
- 결함 유형별 피쳐: 셀전압 결함은 개별 셀 전압의 임계 초과(셀별 min/max, 임계 초과 셀 수)로, 셀편차 결함은 셀 간 불균형(전압 표준편차, 최대-최소 편차)으로 특징을 잡는다.

- 모듈 단위 위치 추정: 차종별 셀→모듈 매핑(예: IONIQ 96셀 = 12모듈×8셀)을 이용해 어느 모듈에서 이상이 두드러지는지 표시한다(KONA·NIRO는 매핑 테이블 별도 필요).
- 건강 지표: 데이터에 실제 SOH 정답이 없으므로, 계산된 Health Index를 SOH 대체 프록시로 사용한다.

5. 프로젝트 수행시 본인의 활동 및 기여

- 주제 방향 제시: 센서데이터로 고장 진단하는 주제 제안
- 데이터 구조 이해 및 활용 방안 분석
- 데이터 경량화 방법 구상, 아이디어 제시
- 모델 선택 및 학습 방법 제안(Mini Rocket)
- 데이터 누수 방지 아이디어 제안(CSV에서 나온 청크에는 동일한 group_key를 부여하고, 하나의 group_key는 학습셋과 검증셋 중 한쪽에만 배정되도록)
- 기준 모델 제안 및 파이프라인 설계(센서 3종 × 차종 3종, 총 9개 슬롯에 대해 각각 별도의 모델을 구축)
- 12채널 융합 모델 제안
- 대시보드 구현(pilot test)
- 발표자료 제작

기타의견 및 건의사항	
-------------------	--